

머신러닝(XGBoost)기반 미국프로야구(MLB)의 투구별 안타 및 홈런 예측 모델 개발*

조선미**, 김주학, 강지연, 김상균 명지대학교

국문초록

최근 야구 종목의 인공지능 기반의 예측 연구는 점진적인 발전을 보이며, 다각도의 연구가 진행되고 있다. 보편적으로 타자의 홈런과 안타를 예측하기 위해서 타구의 발사각도, 타구속도 등의 요인이 활용된다. 그러나 타구결과인 발사각도 및 타구속도는 투수의 투구와 상관성이 높다. 따라서 이 연구에서는 타자의 타격정보를 제외하고, 투수의 투구정보만을 활용하여 홈런과 안타를 예측하는 인공지능 모델을 개발하였다. 모델개발을 위해 2022시즌 미국프로야구(MLB)의 투구데이터를 수집하였으며, 구종, 투구종, 타자위치, 투수주손, 볼카운트, 스트라이크카운트의 변수를 독립변수로 홈런과 안타 결과를 종속변수(예측변수)로 하는 인공지능 모델을 개발하였다. 인공지능 모델은 머신러닝 기법 중 하나인 XGBoost를 사용하여 개발하였다. 개발 결과, 정확도 86.92%, 정밀도 99.90%, 재현율 86.95%, F1 score 92.98% 성능의 인공지능 예측 모델이 개발되었다. 아울러 개발 모델에 미국프로야구(MLB)의 투수인 류현진의 투구데이터를 적용하여 데이터 탐색적 분석을 수행하여, 개인 선수의 보편성과 특징을 확인하였다.

주요어: 인공지능, 기계학습, XGBoost, 야구, 예측, 홈런, 안타

I. 서론

보편적으로 야구는 투수 게임이라는 인식이 강하지만, 야구 경기에서 수비와 관련한 투수 또는 투구가 승리를 견인하는 절대적인 요인으로 설명되지 않는다. 야구는 두 팀이 공격과 수비를 교대하면서 더 많은 점수를 획득하는 팀이 승리하기 때문이다. 즉, 수비만큼 공격도 중요하며, 투수는 상대의 공격을 저지하는 역

할을 수행한다.

야구 경기에서 출루한 주자가 본루로 돌아오면 득점이 인정된다. 득점을 위해서 가장 첫 번째로 수행해야 하는 것은 출루이고, 출루 상황은 안타, 볼넷, 사구, 타격방해 등과 같은 기타 상황을 포함한다. 이 중 안타는 출루의 경우에서 가장 많은 비율을 차지한다(조형석, 2021).

안타는 1루타, 2루타, 3루타 그리고 홈런의 4종으로 구성되어 있고, 타구속도, 발사각도, 타구방향 등의 속성과 관련이 높다. 최근에는 타구의 속성에 따른 공격상황에서 타자의 경기력을 분석하는 연구가 다각도

* 이 논문은 2019년 대한민국 교육부와 한국연구재단의 지원을 받아 수행된 연구임(NRF-2019S1A5A2A0305515).

** 제1저자 조선미(liff99@gmail.com)

경기도 용인시 처인구 명지로 116, 명지대학교

로 진행(홍중선, 신동식, 2017; 한정섭, 정다현, 김성준, 2022)되고 있다. 대표적인 야구의 분석 지표인 세이버메트릭스(Sabermetrics) 또한, 다양한 타자 관련 지표들을 개발·발표하고 있다.

특히, 최근에는 빅데이터를 활용한 예측 지표들이 다양하게 등장하고 있다. 기대타율(xBA), 기대장타율(xSLG) 등은 경기력과 관련한 대표적인 예측값이라 할 수 있다. 이러한 예측 지표의 등장은 인공지능의 발전으로부터 기인한 결과이다. 김주학, 조선미, 강지연(2022)은 스포츠 빅데이터와 인공지능이 경기기록으로 제한적이었던 스포츠 과학에 혁신을 가져오며 새로운 정보원으로서 시각과 통찰, 예측에 대한 가능성을 제시한다고 개진한 바 있다.

기대장타율(xSLG)은 타자가 홈런을 포함한 안타를 쳤을 때, 해당 타구와 비슷한 타구속도와 발사각도의 누적통계를 기반으로 계산되는 장타율의 기대확률값이다. 기대장타율(xSLG)은 수비지표와 구장 특징과 같은 타자 이외의 속성을 배제한다는 것을 전제로 한다. 미국 메이저리그(MLB)의 스탯캐스트(Statcast)는 기대장타율(xSLG)이 수비지표를 배제하므로 고유한 타자의 기술을 의미한다고 설명하고 있다. 그러나 기대장타율(xSLG)을 산출하는 요인인 발사각도, 타구속도는 투수의 투구와 상호 관련성이 높기 때문에, 기대장타율(xSLG)은 ‘완전한 수비지표의 배제’보다는 ‘인플레이 이후의 수비지표의 배제’라고 보는 것이 비교적 타당할 것이다.

수비상황에 마운드에 오르는 투수는 일차적으로 타자의 출루와 주자의 진루를 막아야하고, 만약 인플레이 상황이 발생한다면, 득점을 최소화하기 위한 효율적 운영을 해야 한다. 야구경기에서 인플레이 상황은 타격된 공이 페어지역으로 들어간 상황을 말하며, 인플레이 상황의 결과는 안타, 홈런, 아웃, 에러, 야수선택 등이다.

인플레이 상황에서 홈런과 안타는 실점 또는 실점 위기를 초래한다. 투수의 관점에서 피홈런과 피안타

중 무엇이 더 중요한지는 상황에 따라 다를 수 있지만, 야수의 행동에 영향을 받는 안타가 홈런보다는 비교적 덜 위험하다고 할 수 있다. 예컨대 홈런은 수비행위의 기회가 완전소실되지만, 안타의 경우 호수비로 2루타가 되었을 법한 타구를 1루타로 저지하거나 주자 잔루 또는 타자의 노림수를 미리 예측 하는 등의 기회가 있다.

Otremba Jr.(2022)는 투수의 투구전략에서 타자가 안타와 홈런을 치지 못하도록 구종와 스피드, 스핀, 투구위치 등을 조작해야하고, 타자와 투수의 조건에 따라 인플레이 상황이 변칙적임을 논의하였다. 아울러 타격 매커니즘은 투구의 매커니즘과 상관성이 높음을 개진하였다. 이는 타격된 공의 타구방향, 타구속도, 발사각도는 투구의 속성과 관계가 높음을 시사한다.

이 연구는 홈런과 안타를 투수의 관점에서 접근한 연구이다. 현재까지 타율 및 장타율 관련 예측 지표 또는 예측 연구는 신동윤, 김진호(2022), 한정섭 외(2022)의 연구와 같이 타격결과를 기반으로 진행된 연구가 주를 이뤘다. 하지만, 타격은 결국 투수의 투구가 선행위 되어야만 가능하기 때문에 투수가 어떤 공을 어떤 상황에서 투구하는가에 따라 안타와 홈런의 결과는 차이가 있을 것이다.

이에 이 연구에서는 타자의 타격결과를 모두 배제하고, 투수의 투구조건과 상황조건을 기반으로 홈런과 안타를 예측하는 인공지능 모델을 개발하고, 개발 모델에 개별자료를 적용하여 상황 또는 개인적 특징을 탐색하였다.

홈런과 안타를 예측하기 위해 인공지능의 머신러닝 기법 중 하나인 XGBoost(Extreme Gradient Boosting)를 적용하였다. XGBoost는 여러개의 의사결정나무(Decision Tree)를 조합해서 사용하는 앙상블 부스팅 모델이다. CART(Classification and Regression Tree) 기반이기 때문에 분류 예측과 회귀가 가능하다. 뿐만 아니라, 병렬처리를 진행하므로 학습과 예측의 시간적 효율이 있고, 알고리즘 자체에

과적합 규제 기능이 포함되어 강한 내구성을 보장한다. 최근, XGBoost는 다양한 예측 연구에서 성능과 효과성을 입증하며, 스포츠 과학 분야에서도 활발하게 사용되고 있다.

최형준(2022)은 축구 경기 결과를 예측하기 위해 다양한 머신러닝 기법을 비교하였는데, 연구결과 XGBoost 모델에서 높은 F1 score를 확인하였다. 한정섭 외(2022) 또한, 한국프로야구(KBO) 타자들의 OPS예측을 위해 머신러닝 기법을 비교 분석하였는데, 연구에서 XGBoost가 가장 높은 성능을 보였다.

이 연구는 XGBoost를 적용하여 야구 경기의 인플레이 타구 중 안타와 홈런을 예측하는 인공지능 모델을 개발하고, 개발 모델에 개인 투수의 자료를 적용하여, 투구별로 홈런과 안타의 예측결과를 탐색하는데 그 목적이 있다. 개발 인공지능 모델은 미국프로야구(MLB)의 전체 투구데이터 및 누적데이터를 기반으로 리그의 보편성을 따른다. 그러므로 개발한 인공지능 모델에 개인 데이터를 적용하고 예측결과를 탐색함으로써 투수 개인의 투구 특성을 확인할 수 있다. 또한, 이 연구를 통해 산출되는 투구별 예측결과는 야구경기의 전술·전략 및 운영의 자료로 활용됨을 기대한다.

II. 연구방법

1. 자료수집

연구의 목적 달성을 위해 미국 메이저리그(MLB)의 스탯캐스트(Statcast)에서 제공하는 2022시즌 전체 투구에 해당하는 투구 관련 자료를 수집하였다. 투구 자료는 경기당 투수의 통계 자료가 아닌 투구된 각각의 모든 공과 관련한 정보이며 원데이터(raw data)형태의 수집을 원칙으로 하였다. 미국메이저리그(MLB)에 소속된 30개 팀의 한시즌 경기는 팀별 162경기이며 수집된 자료는 다음 <표 1>과 같다.

표 1. 수집 자료

시즌	전체 팀 경기수	투구수
2022	4,860	733,486


2. 측정변수

XGBoosts 기반 안타 및 홈런 예측 모델 개발에 사용할 측정변수는 총 8개로 <표 2>와 같다.

측정변수는 예측에 라벨이 되는 타격 결과(홈런 또는 안타)인 종속변수, 투구의 속성과 상황을 나타내는 독립변수로 구분하였다.

표 2. 측정변수

항목	내용	속성(종류)	타입
예측결과 · 종속	event ▷ 투구결과 ▷ hit-into-play 된 타구 중 안타와 홈런만 측정	▷ 안타 : 1루타(single), 2루타(double), 3루타(triple) ▷ 홈런(homerun)	명목
	pitch_type	구종 ▷ 직구 : 패스트볼(4심), 싱커(2심), 커터, 컷패스트볼 ▷ 변화구 : 슬라이더, 커브, 너클커브, 슬로우커브, 너클, 이퍼스, 슬로브, 스위퍼 ▷ 오프스피드 : 스플릿핑거, 체인지업, 포크볼, 스크류볼	명목
예측을 위한 투입변수 · 독립	release_speed	투구속도 단위 : 마일(mph)	연속
	zone	투구존 1번~14번	명목
	stand	타자위치 좌타 / 우타	명목
	p_throws	투수주손 좌완 / 우완	명목
	Balls	볼카운트 0~3	이산
	strikes	스트라이크카운트 0~2	이산



측정변수 중 투구존(zone)은 메이저리그(MLB)에서 분류하는 기준으로 14개 구역으로 범주화하였다 <표 2>. 투구존은 포수관점에서 포구위치의 좌표를 기반으로 측정되었으며, 스트라이크존과 볼존을 의미한다.

3. 자료전처리

인공지능 예측 모델 개발 환경에 적합하도록 측정변수의 전처리 과정을 수행하였다. 측정변수의 전처리는 자료의 무결성 확인, 자료의 범주화, 자료의 선택 등 세 단계로 진행되었다. 인공지능 모델의 경우 보편적으로 명목변수는 더미변수화하는 원핫인코딩을 진행하지만 XGBoost 모델의 경우 범주형 데이터의 분석을 지원하지므로 추가적으로 진행하지 않았다.

예측 모델의 자료는 이상치와 null값이 있는 경우 예측 성능이 떨어지거나 개발 효율이 떨어지므로 수집 자료의 무결성을 검토하여 타당하지 않다고 생각되는 투구는 삭제하였다. 미국프로야구(MLB)는 야구의 구종을 16개로 구분하고 있다. 이 연구에서는 16개의 구종을 직구, 변화구, 오프스피드 3종으로 범주화하였다 <표 2>.

아울러 연구의 목표가 안타와 홈런을 예측하는 것이므로 인플레이 타격 중 안타와 홈런 자료를 선택하였다. 자료전처리 후 최종적으로 40,257건의 투구를 분석 자료로 선정하였고, 각각의 투구(row)에 대하여 8개의 측정변수(column)정보를 행렬(40,257*8)로 구성하였다.

4. 예측을 위한 머신러닝 기법

1) XGBoost(Extreme Gradient Boosting)

XGBoost는 선형 또는 트리 기반 모델에서 과적합 문제를 해결하고 대규모 데이터 세트의 안정성 및 훈련 속도를 개선하기 위해 Chen and Guestrin(2016)이 빅데이터, 함수 및 결과변수 사이의 복잡한 관계를

효율적으로 해결하기 위해 제안한 알고리즘이다. 부스팅 기법의 대표적 알고리즘인 Gradient Boost를 병렬 학습으로 구현한 알고리즘이기 때문에 성능과 효과가 매우 긍정적으로 평가된다.

XGBoost 모델은 기본적으로 의사결정나무(Decision Tree)에 기반하여 학습하며 잔차를 토대로 이전에 사용된 모델을 보완하는 방식으로 학습하는 머신러닝 기법의 한 종류이다(한정섭 외, 2022, 최형준, 2022에서 재인용).

2) XGBoost의 예측값 계산식

XGBoost 모델은 의사결정나무가 몇 가지가 되든지 모두 반영하여 계산할 수 있다는 장점을 지니고 있으며 각 트리로부터 받은 값들을 합쳐서 최종 예측값으로 결정된다(Chen & Guestrin, 2016, 최형준, 2022에서 재인용). 앙상블 모델에서 k개의 트리를 고려한 예측값 계산식은 다음과 같다(수식 1).

$$\hat{y}_i = \phi(x_i) = \sum_{k=1}^k f_k(x_i), f_k \in F,$$

출처. 최형준, 2022

수식 1. XGBoost 예측값 계산식

XGBoost의 학습의 계산식은 다음 <수식 2>와 같다. t번째 iteration에 해당하는 손실함수는 투입된 데이터 수 만큼 반복 학습을 진행한다.

$$L^{(t)} = \sum_{i=1}^n l(y_i, \hat{y}_i^{(t-1)} + f_t(x_i)) + \Omega(f_t) + Constant$$

* $\hat{y}_i^{(t-1)}$: (t-1)번째 iteration에서 도출된 예측값

* $\Omega(f_t)$: 정규화 함수

* Constant : (t-1)번째 iteration까지의 정규화 함수의 합

출처. 최형준, 2022

수식 2. XGBoost 학습 계산식

3) 모델성능 평가

개발 예측 모델의 성능평가를 위해 정확도(accuracy), 정밀도(precision), 재현율(recall), F1 score 지표를 사용하였다.

5. 모델개발

XGBoost 기반의 홈런 및 안타 예측 모델은 2022 시즌 데이터(40,257 투구)를 기반으로 개발하였다. 개발된 모델에 미국프로야구(MLB) 투수인 류현진의 모든 피안타 및 피홈런 투구를 적용하여, 총 958개의 투구별 홈런과 안타의 예측결과를 도출하였다.

수집된 자료는 엑셀 csv 파일로 1차 정리하였고, 모델개발은 Python 언어를 사용하였다. <표 3>은 구체적인 연구의 개발 환경을 정리한 표이다.

표 3. 모델 개발의 물리적 환경

항목	내용
사용언어	Python 3.8.3
	xgboost
설계 및 개발	pandas
프레임워크,	numpy
시각화	matplotlib
	scikit-learn
	seaborn

III. 연구결과

1. XGBoost 기반 홈런 및 안타 예측 모델 개발

전처리된 2022시즌 데이터 행렬을 대상으로 개발한 XGBoost(Extreme Gradient Boosting) 분류 모델(XGBoost for Classification)은 결과 예측값이 홈런 또는 안타인 dual-class 분류 모델로 설계되었다. 보편적으로 분류를 목적으로 하는 XGBoost 모델은 잔차를 예측하는 의사결정나무(Decision Tree)를 생성한다.

XGBoost의 잔차를 예측하는 과정은 총 5단계로 구성된다. 첫 번째 리프(leaf)를 만들고, 두 번째 단계에서 확률적 유사 잔차를 계산한 뒤, 세 번째 단계에서 유사 잔차를 예측할 다음 트리를 만든다. 네 번째 단계에서 예측값을 산출하고, 최대 개수의 트리에 도달하거나, 잔차가 한계에 도달할 때까지 두 번째에서 네 번째 단계를 반복한다.

<그림 1>는 이 연구에서 설계한 잔차를 예측하는 의사결정나무를 도식화한 것이다.




그림 1. 잔차 예측 의사결정트리 구조

개발 모델의 파라미터는 다음과 같이 설정하였다.

표 4. 개발 모델 파라미터

	항목	내용
일반	booster	gbtree
	n_estimators	100
		트리기반모델
		트리개수
	min_child_weight	1
주요 모델 파라미터		자식마디에서 필요한 모든 관측치에 대한 가중치의 최소합
	max_depth	6
		트리의 최대 깊이
학습 태스크	gamma	0
		트리의 최소 손실 감소 값
	objective	softprob
		softmax를 사용, 클래스에 대한 예상 확률 반환
	학습비	8:2
		모델 학습과 테스트

2. XGBoost 기반 홈런 및 안타 예측 모델 결과 및 성능평가

연구 설계에서 설정한 변수 및 모델 개발 결과 정확도 86.92%의 홈런 및 안타 예측 모델이 개발되었다. 타격결과가 아닌 투수의 투구 자료(구종, 투구속도, 투구존, 타자위치, 투수주손, 볼-스트라이크카운트)를 기반으로 예측되었고, 예측 기반 변수가 7종인 것을 고려하였을 때, 비교적 안정적이고 우수한 성능의 예측 모델이 개발되었다고 판단한다.

〈표 5〉는 개발된 예측 모델의 예측결과와 성능평가 결과를 나타낸 표이다.

표 5. 모델 개발 결과

항목	내용
데이터	MLB 2022 시즌 40,257 투구
학습 : 테스트	32,205 : 8,052
예측결과	XGBoost 모델
	예측값
	홈런
	안타
성능평가	실제값
	홈런
	안타
	정확도
성능평가	정밀도
	재현율
	F1 score

〈그림 2〉는 개발된 홈런 및 안타 예측 모델에 투입된 변수의 중요도를 나타낸 것이다.




그림 2. 개발 모델의 투입변수 중요도

개발한 인공지능이 예측을 수행할 때 가장 중요한 고려한 변수는 투구속도(release_speed)이며, 두 번째 주요 변수는 투구존(zone)이었다.

투구속도가 너무 빠르면 파울이 되거나 뜬공이 되고, 너무 느리면 타자의 타이밍을 뺏으며, 피홈런 투구는 일정 범위의 속도가 있다는 보편적 인식을 시사하는 부분이다. 또한, 한국 프로야구(KBO) 투수 안우진(24, 키움히어로즈)은 2022시즌 피홈런에 대하여 “‘잘 들어갔다’ 싶은 공이 맞은 건 하나도 없었다. 내가 원하는 곳에 던지기만 하면 좋은 타구가 나오지 않을 거란 믿음이 생겼다. 한방 있는 타자들만 조심하면 될 것 같다(김영록, 2022).”라는 인터뷰를 한 바 있다. 이는 투구존의 중요성을 언급한 것인데, 야구에서 타자들의 스윙선택 시 대부분 선호하는 코스가 있기 때문에, 투수가 타자가 원하는 위치로 투구하지 않는 것과 같은 맥락으로 이해할 수 있다.

그 밖의 변수 중요도에서 가장 낮은 중요도를 보인 변수는 구종(pitch_type)이었다. 구종은 투구속도 및 투구존과 상관이 높은 변수인데 예측 모델의 중요도 순위의 차이가 있는 이유는 Boosting 모델이 다중 공선성의 문제를 개선한 모델로 평가(이인호, 이경섭, 2020)받기 때문이라 판단된다. 아울러 자료전처리 과정에서 16개의 구종을 3가지로 범주화했기 때문에 구종에 대한 변별력이 다소 감소했을 것으로 판단한다.

3. XGBoost 기반 홈런 및 안타 예측 모델의 적용 및 데이터 탐색적 접근

1) 적용 결과

미국프로야구(MLB) 투수인 류현진(35, 토론토블루제이스)의 투구 자료를 수집하여 개발한 인공지능 예측 모델에 적용하였다. 2013시즌부터 2022시즌까지 류현진의 총 투구수는 15,890개이며, 이중 피안타와 피홈런 투구는 총 958건이다(표 6).

표 6. 류현진의 피안타와 피홈런 투구

항목	N	합계
안타	1루타 635	851
	2루타 204	
	3루타 12	
홈런	107	958

〈표 6〉의 958개의 투구에 대하여 구종, 투구속도, 투구존, 타자위치, 투수주손, 볼-스트라이크카운트 정보를 투입하여 각 투구의 홈런과 안타를 예측하였다.

예측결과 예측에 성공한 TRUE 값이 848건, 예측에 실패한 FALSE 값이 110건으로 88.62%의 정확도(accuracy)를 보였다. 개발된 모델 성능의 정확도(accuracy) 값(86.92%)과 일관된 결과를 보였다고 할 수 있다.

〈그림 3〉은 류현진의 투구별 홈런 및 안타의 예측결과를 일부 발췌한 것이다. 〈그림 3〉은 투구(row)별로 안타와 홈런의 예측결과를 나타내는데 〈그림 3〉의 종속변수(event, 0:홈런, 1:안타)는 예측값의 정확도 확인을 위한 값으로, 모델 적용시에는 투입되지 않았다. 즉, 투수의 투구정보와 선수정보, 볼카운트와 같은 상황정보만을 이용하여 예측결과를 도출한 것이다. 이는 이 연구에서 개발한 인공지능 예측 모델을 활용하면, 투수의 투구에 따른 실시간 타격결과를 예측할 수 있음을 의미한다.

2) 개별 선수의 특징

이 연구에서 개발한 예측 모델을 적용했기 때문에 모델이 생각하는 투입변수의 중요도는 동일하다. 하지만 모든 선수의 투구자료가 아닌 개별 선수의 투구자료이기 때문에 주요 항목에 대하여 특징을 살펴볼 필요가 있다.

(1) 투구속도

적용한 류현진의 홈런과 안타의 투구속도에 대한 기술통계는 다음 〈표 7〉과 같다.

표 7. 투구속도의 실제값과 예측값

항목	Mean	SD	Q1	Q2	Q3
실제값	홈런 85.94	5.78	81.9	88.1	90.1
	안타 85.40	6.10	80.8	87.2	90.5
예측값	홈런 78.04	4.53	74.2	77.9	82.0
	안타 85.50	6.05	80.9	87.4	90.5

〈표 7〉에 따르면 실제 관측치의 홈런과 안타의 투구속도의 차이가 거의 없다는 것을 확인할 수 있다. 류현진 선수는 2013시즌부터 2022시즌까지 모든 투구에서 제구와 속도의 변화가 비교적 적은편으로 평가되는 선수이다(표 8). 특히, 류현진은 대부분의 모든 구종을 같은 모션(와인드업, 킥, 양손분리, 스트라이드, 릴리스 포인트, 팔로스로)으로 투구하는 강점이 있는 선수이다.

예측에 투입된 변수							종속변수	예측결과	
pitch_type	release_speed	zone	stand	p_throws	balls	strikes	event	pred_event	F/T
row 전체 투구 ↓	2	71.4	5	1	2	1	1	1	TRUE
	3	77.9	6	1	2	3	1	0	TRUE
	1	87.6	6	1	2	2	1	1	TRUE
	3	77.9	6	1	2	0	1	1	TRUE
	1	84.5	2	1	2	2	0	1	FALSE
	1	88	3	2	2	0	1	1	TRUE
	3	80.4	8	1	2	2	0	1	TRUE
	2	88.1	4	1	2	2	0	1	TRUE

그림 3. 류현진의 홈런 및 안타 예측결과

표 8. 류현진의 연도별 투구속도

연도	N	Mean	SD	최대값	최소값
2013	3,065	85.37	6.94	95.3	50.3
2014	2,354	86.22	6.83	95.7	48.6
2016	89	84.38	8.40	92.6	57.5
2017	2,110	83.83	6.79	94.2	66.2
2018	1,237	84.57	6.36	93.5	63.8
2019	2,705	84.74	6.40	93.9	64.9
2020	1,132	83.54	6.03	92.9	67.1
2021	2,689	84.38	5.84	93.9	67.4
2022	395	82.88	6.94	92.9	68.5
합계 결측치제외	15,776	84.75	6.59	95.7	48.6

반면, 인공지능 예측 모델이 홈런과 안타라고 예측한 투구의 속도는 실제값과 달리 다소 차이가 있음을 확인할 수 있다. 개발한 인공지능은 피홈런 투구의 평균 투구 속도를 안타보다 7.46mph 느리게 판단하고 있다. 이는 모델 개발의 원데이터(raw data)인 2022 시즌 투구데이터를 살펴 보았을 때 어느정도 그 원인을 파악할 수 있다. 2022시즌 빠른 직구보다 비교적 느린 변화구에서 홈런이 더 많이 발생하였고, 빠른 투구는 파울이 되는 경우가 많았다. 이 연구의 예측값이 전체 선수의 누적데이터를 기반으로 모델링된 확률모델이기 때문에 발생하는 특성으로 판단된다.

(2) 투구존

개발한 인공지능 모델에서 홈런 또는 안타로 예측한 결과의 투구존은 <그림 4>와 <그림 5>와 같다. 류현진의 투구가 홈런이라고 예측한 공은 대부분 스트라이크존 정중앙인 5번 영역으로 예측되었다. 그리고 안타로 예측한 구역은 정중앙인 5번 지역과 포수관점 오른쪽 즉, 좌타자의 몸쪽인 6번 지역, 몸쪽 아래인 9번 지역으로 비교적 넓게 분포되었음을 확인할 수 있다.

예측 투구존은 실제로 류현진의 피홈런 및 피안타 투구존과 동일한 결과로 2022시즌의 결과와도 동일한 양상을 보였다.




그림 4. 류현진의 예측 피홈런존




그림 5. 류현진의 예측 피안타존

(3) 기타 특징

류현진은 좌완투수이기 때문에 미국메이저리그(MLB)에서 우타자를 상대하는 경우가 상대적으로 많다. 좌타자 233명 중 홈런 25(10.7%), 안타 208(89.3%), 우타자 725명 중 홈런 82명(11.3%), 안타 643명(88.7%)을 기록했다. 2022시즌 전체기록 중 류현진과 같은 좌완투수의 기록을 살펴보면 좌타자 상대 홈런은 5.29%, 우타자 상대 홈런은 21.76%를 기록했고, 안타는 좌타자 상대 6.62%, 우타자 상대 20.96%를 기록했다.

류현진의 시즌 전체 좌·우타자 비율로 보았을 때, 우타자보다는 좌타자의 홈런과 안타의 비율이 높음을 확인할 수 있다.

개발한 인공지능 모델에 개인기록을 적용하고, 데이터를 기반으로 탐색해본 결과 류현진의 피안타와 피홈런의 투구속도는 보편적인 특성에서 다소 벗어난 특징을 확인하였고, 투구존의 경우는 매우 비슷한 특징을 확인하였다. 또한, 이러한 개인 선수의 특징은 개발 인공지능에 적용한 류현진의 예측 정확도 88.62%와 관련이 있을 것으로 판단된다.

IV. 논의 및 결론

스포츠과학분야에서 안타와 홈런에 대한 연구 또는 문제는 대부분 타자의 타구속도, 발사각도, 타구방향 등의 결과 요인(Hamilton et al., 2014, 홍중선, 신동식, 2017, 신동운, 김진호, 2022)으로 설명되었다. 홈런과 안타는 타격결과이기 때문에 타자 관점의 연구는 필연적으로 당연하다. 그러나 타구속도와 발사각도는 투수의 투구와 밀접한 관련이 있다. 이에 이 연구에서는 타자의 결과요소를 배제하고, 투구속성과 상황조건을 기준으로 홈런과 안타를 예측하는 인공지능 예측 모델을 개발하였다.

인공지능 예측 모델 개발을 위해 머신러닝 방법 중 하나인 XGBoost(Extreme Gradient Boosting)를 사용하였다. XGBoost는 분류 및 회귀가 가능한 앙상블 부스팅 모델로 최근 다양한 분야의 예측에서 성능을 입증(한정섭 외, 2022, 최형준, 2022) 받고 있는 알고리즘이다.

인공지능 예측 모델 개발을 위해 2022시즌 구종, 투구속도, 투구존, 타자위치, 투수주손, 볼카운트, 스트라이크카운트 자료를 수집하여 모델을 개발하였다. 개발 결과 정확도 86.92%, 정밀도 99.90%, 재현율 86.95%, F1 score 92.98% 성능의 인공지능 예측 모

델이 개발되었다. 개발 모델의 변수 중요도는 투구속도, 투구존 순이었다.

투구속도는 타격의 발사각도 및 타구속도와 상관이 높은(Gray, R., 2009) 요인이기 때문에 타격결과인 홈런과 안타를 예측하는 모델에서도 중요한 변수로 나타났다. 또한, 타자는 선호하는 투구가 선호하는 코스가 있기 때문에, 투구존은 타자의 스윙선택(조형석, 2021)과 관련이 있다. 보편적으로 홈런은 투수의 실투에서 비롯된다는 인식이 있다. 투수의 실투는 제구의 실패로 이어지는데, 안우진(24, 키움히어로즈), 류현진(35, 토론토블루제이스)은 본인의 피홈런에 대하여 투구존(코스)의 중요성을 언급(김영록, 2022, 온다예, 2019)한 바 있다.

개발한 예측 모델에 미국메이저리그(MLB)의 투수인 류현진의 투구자료를 적용하여 개별 투구 단위로 홈런과 안타의 예측결과를 확인하였다. 적용 결과 홈런과 안타의 예측 정확도는 88.62%로 나타났다. 이후 류현진의 투구에 대한 개별 데이터와 상황에 대한 탐색적 접근을 수행하였다. 예측 모델 개발시, 미국프로야구(MLB)의 2022시즌 전체 투구자료를 기반으로 개발하였기 때문에 개발된 예측 모델은 비교적 보편성을 보장한다고 할 수 있다. 따라서 적용 결과에 대한 데이터 탐색적 접근을 수행하므로써 개인 투수의 특성을 확인할 수 있다.

류현진의 경우 실제값과 예측값을 비교하였을 때, 모델에서 중요도가 가장 높았던 투구속도 보다 투구존에서 좀 더 정밀한 결과를 확인할 수 있었다. 이는 인공지능 모델이 주요하게 생각한 변수는 인공지능이 모델 개발의 예측, 판단할 시 중요하게 생각한 변수라는 것이지, 반드시 모든 개별 데이터 간의 양적인 차이가 있다는 것을 의미하는 것은 아님을 시사한다. 류현진의 투구존은 미국메이저리그(MLB) 2022시즌 피안타, 피홈런의 보편적인 특징과 거의 동일한 패턴임을 확인하였다. 이는 류현진이 비교적 제구가 좋은 선수이고, 일관된 투구 모션을 가지고 있는 선수로 평가됨

을 반영한 결과로 판단한다.

마지막으로, 이 연구에서 데이터의 해석을 위해 개별 선수의 적응 결과를 주요변수별로 탐색하였으나 인공지능의 예측은 하나의 변수를 독립적으로 파악한 것이 아니라 투입변수들의 종합적인 관점에서의 예측이 수행되었음을 확인한다.

종합적이고, 복합적인 판단이 필요한 스포츠 영역의 예측 인공지능은 때론 전체를 바라보는 거시적 시각이 필요하기도 하고, 또 다른 한편으로는 부분을 바라보는 미시적 시각이 필요하기도하다(김주학 외, 2022). 이 연구에서 모델 개발에 투입한 자료는 2022 한 시즌 자료였으나 보다 많은 양의 빅데이터가 수집된다면 모델의 성능은 더욱더 향상될 것이다. 아울러 개인 선수의 특성을 반영한 예측을 위해서는, 누적데이터를 통한 보편적 예측 모델 개발과 동시에 개인 선수의 누적데이터만을 활용한 모델 개발이 필요하다. 다만, 이를 위해 개인의 기록이 빅데이터 수준으로 수집되는 것이 선행되어야 한다.

이 연구의 예측 모델은 타자의 타격결과를 예측 요인으로 설정하지 않았기 때문에 현장에서 실시간 결과를 예측하고, 피드백 자료로 활용될 수 있다. 기대장타율(xSLG)와 같은 기존의 타격 관련 예측값은 타자의 타격결과가 반드시 필요하지만 이 연구에서 개발한 예측 모델은 오로지 투구정보를 활용하여 개발되었기 때문이다. 또한, 투수와 타자의 훈련자료 및 선발, 라인업 등의 운영자료로 활용됨을 기대한다.

참고문헌

- 김영록, “시즌 피홈런 단 4개…[홈런? 실투 안하면 안 맞는다] 에이스의 이유 있는 미소”, 스포츠조선, 2022년 10월 13일자. <https://www.chosun.com/sports/baseball/2022/10/13/3S6DJTAW45IBTQ4F5UF3KOQP4Q/>
- 김주학, 조선미, 강지연(2022). 야구 경기 승패 예측을 위한 합성곱 신경망(CNN) 최적화 연구. **한국체육측정평가학회지**, 24(4), 153-165. <http://doi.org/10.21797/ksme.2022.24.4.153>
- 서영진, 문형우, 우용태(2019). 기계학습 기법을 이용한 한국 프로야구 승패 예측 모델. **한국컴퓨터정보학회논문지**, 24(2), 17-24. <http://doi.org/10.9708/jksci.2019.24.02.017>
- 신동윤, 김진호(2022). 한국프로야구에서 장타율과 출루율(OPS) 예측 연구. **한국빅데이터학회지**, 7(1), 49-61. <http://doi.org/10.36498/kbigdt.2022.7.1.49>
- 온다예, “류현진 [만루홈런은 실투 때문…제구가 아쉬워]”, 뉴스1코리아, 2019년 8월 24일자. <https://www.news1.kr/articles/?3703030>
- 이인호, 이경섭(2020). 트리 기반 앙상블 방법을 활용한 자동 평가 모형 개발 및 평가: 서울특별시 주거용 아파트를 사례로. **한국데이터정보과학회지**, 31(2), 375-389. <http://doi.org/10.7465/jkdi.2020.31.2.375>
- 조형석(2021). **MLB 타자들의 스윙존에 따른 스윙선택 성향 분석**. 미간행 석사학위논문. 명지대학교 기록정보과학전문대학원. <http://dcollection.mju.ac.kr/common/orgView/000000076289>
- 최형준(2022). 축구의 경기 결과 예측을 위한 머신러닝 기법 비교. **한국체육측정평가학회지**, 24(4), 81-91. <http://doi.org/10.21797/ksme.2022.24.4.081>
- 한정섭, 정다현, 김성준(2022). 머신러닝을 활용한 빅데이터 분석을 통해 KBO 타자의 OPS 예측. **차세대융합기술학회논문지**, 6(1), 12-18. <https://www.earticle-net-ssl.openlink.mju.ac.kr/Article/A407201>
- 홍종선, 신동식(2017). 2017년 한국프로야구 타자력 예측모형 개발. **한국데이터정보과학회지**, 28(3), 635-345. <http://doi.org/10.36498/kbigdt.2022.7.1.49>
- Chen, T., & Guestrin, C. (2016). XGBoost: A Scalable Tree Boosting System. *Proceedings of the 22nd ACM SIGKDD International Conference on Knowledge Discovery and Data Mining*, 785-794. <https://doi.org/10.1145/2939672.2939785>
- Gray, R. (2009). A model of motor inhibition for a complex skill: Baseball batting. *Journal of Experimental Psychology: Applied*, 15(2), 91-105. <https://doi.org/10.1037/a0015591>
- Hamilton M., Hoang P., Layne L., Murray J., Padget D., Stafford C. and Tran H. (2014). Applying machine learning techniques to baseball pitch prediction. *In Proceedings of*

the 3rd International Conference on Pattern Recognition Applications and Methods (ICPRAM-2014), 520-527.
<https://doi.org/10.5220/0004763905200527>

Otremba Jr., Stephen Eugen (2022). *SmartPitch: Applied Machine Learning for Professional Baseball Pitching Strategy*. degree of Master of Engineering in Electrical Engineering and Computer Science. Massachusetts Institute of Technology. <https://hdl.handle.net/1721.1/145144>

저자정보

조선미(Sun-Mi CHO)

명지대학교 스포츠기록분석연구센터 분석팀장
liff99@gmail.com

김주학(Joo-Hak KIM)

명지대학교 스포츠학부 교수
kjhak@mju.ac.kr

강지연(Ji-Yeon KANG)

명지대학교 스포츠기록분석연구센터 분석부팀장
jyconniek@gmail.com

김상균(Sang-Kyun KIM)

명지대학교 융합소프트웨어학부 교수
goldmunt@mju.ac.kr

논문투고일	2023년 03월 06일
심사완료일	2023년 03월 26일
게재확정일	2023년 03월 27일

Abstract

The Korean Journal of Measurement and Evaluation in Physical Education and Sport Science. 2023, 25(1), 65-76

Development of Hit and Home-Run Prediction Model for Each Pitch in Major League Baseball(MLB) Based on Machine Learning(XGBoost)

Sun-Mi CHO, Joo-Hak KIM, Ji-Yeon KANG, Sang-Kyun KIM *Myongji Univ.*

Recently, research on artificial intelligence-based prediction of baseball has been gradually developed, and various studies are being conducted. In general, variables such as launch angle and launch speed are used to predict hitters' home-run and hit. However, launch angle and launch speed(batting results) are correlated with the pitcher's pitching. Therefore, in this study, the artificial intelligence model that predict home-run and hit was developed using only the pitcher's pitching information, excluding the batting information of the hitter. To develop the artificial intelligence model, pitching data from the 2022 season of the Major League Baseball (MLB) collected. (independent variable : pitch type, release speed, zone, stand, pitch throws, ball count, strike count / dependent(prediction) variable : hit and home-run) The artificial intelligence model was developed using XGBoost, one of the machine learning method. As a result of the development, the artificial intelligence model performance was accuracy 86.92%, precision 99.90%, recall 86.95%, and F1 score 92.98%. Ryu Hyun-jin(MLB pitcher)'s pitching data was applied to the developed artificial intelligence model and confirmed characteristics of individual.

Keywords: Artificial Intelligence(AI), Machine Learning(ML), XGBoost, baseball, Prediction, home-run, hit