



저작자표시-비영리-변경금지 2.0 대한민국

이용자는 아래의 조건을 따르는 경우에 한하여 자유롭게

- 이 저작물을 복제, 배포, 전송, 전시, 공연 및 방송할 수 있습니다.

다음과 같은 조건을 따라야 합니다:



저작자표시. 귀하는 원저작자를 표시하여야 합니다.



비영리. 귀하는 이 저작물을 영리 목적으로 이용할 수 없습니다.



변경금지. 귀하는 이 저작물을 개작, 변형 또는 가공할 수 없습니다.

- 귀하는, 이 저작물의 재이용이나 배포의 경우, 이 저작물에 적용된 이용허락조건을 명확하게 나타내어야 합니다.
- 저작권자로부터 별도의 허가를 받으면 이러한 조건들은 적용되지 않습니다.

저작권법에 따른 이용자의 권리는 위의 내용에 의하여 영향을 받지 않습니다.

이것은 [이용허락규약\(Legal Code\)](#)을 이해하기 쉽게 요약한 것입니다.

[Disclaimer](#)

석사학위논문

인공지능을 활용한 한국 프로야구(KBO) 경기 승패 예측 모형 분석 연구

A Study on the Analysis of Win-loss Prediction Models on
KBO Matches Based on AI

제 출 자 : 양 해 준
지도교수 : 최 형 준

2024

스포츠사이언스융합학과
스포츠경기분석전공
단국대학교 일반대학원

인공지능을 활용한 한국 프로야구(KBO) 경기 승패 예측 모형 분석 연구

A Study on the Analysis of Win-loss Prediction Models on
KBO Matches Based on AI

이 논문을 석사학위논문으로 제출함

2024년도 6월

단국대학교 일반대학원
스포츠사이언스융합학과
스포츠경기분석전공

양 해 준

양 해 준의 석사학위 논문을
합격으로 판정함

심 사 일 : 2024. 06. 03.

심사 위원장

金 用 均



심 사 위 원

李 允 洙



심 사 위 원

崔 炯 峻



단국대학교 대학원

(국문초록)

인공지능을 활용한 한국 프로야구(KBO) 경기 승패 예측 모형 분석 연구

단국대학교 대학원 스포츠사이언스융합학과

스포츠경기분석전공

양 해 준

지도교수 : 최 형 준

이 연구는 2019년, 2020년, 2021년, 2022년, 2023년 한국 프로야구(KBO) 정규리그 경기의 팀 기록을 토대로 승패 예측에 대하여 모델별로 예측정확도 평가지표들을 비교하고, 설명가능한 인공지능(XAI)을 활용하여 모델별로 예측 과정 속에서 변인들의 중요도 및 영향력을 분석하고자 실시하였다.

연구 대상은 2019년, 2020년, 2021년, 2022년, 2023년 KBO 정규리그 전체 3,600경기 중 무승부 94경기들을 제외한 총 3,506경기들을 대상으로 하였으며, 타수, 안타, 홈런, 타점, 볼넷, 사구, OPS, WHIP, ERA 등 총 22개의 독립변인과 1개의 종속변인 승패를 사용하였다.

먼저 기술통계를 통해 변인별 평균, 표준편차, 최소값, 최대값을 확인하였고, 상관분석과 다중공선성을 분석하여 승패 예측에 최종적으로 사용할 기록 변인들을 선별하였다. 그리고 랜덤포레스트 모델, XGBoost 모델, 딥러닝 모델 총 세 종류의 모델을 활용하여 승패 예측을 수행하였고, XAI의 SHAP를 통해 각 모델의 예측 과정 속에서 사용된 변인들의 중요도 및 영향력을 분석하였다.

연구 결과는 첫째, 승패 예측에 대한 모델별 예측정확도 평가는 정확도, 정밀도, 재현도, F1-Score로 진행하였고, 랜덤포레스트부터 정확도 91.2%, 정밀도 91.2%, 재현도 91.1%, F1-Score 91.1%를 나타냈고, XGBoost는 정확도 92.6%,

정밀도 92.4%, 재현도 93.0%, F1-Score 92.6%를 나타냈으며, 딥러닝은 정확도 90.2%, 정밀도 92.4%, 재현도 90.5%, F1-Score 90.2%를 나타냈다.

둘째, XAI의 SHAP로 각 모델의 승패 예측에서 사용된 변인들의 절대적 영향도는 랜덤포레스트는 ERA, OPS, 승계주자실점률, K%, 볼넷, 삼진, 실책, BB%, 사구, 홈/어웨이, 팀 이름 변인들 순으로 나타났고, XGBoost는 ERA, OPS, 홈/어웨이, 실책, K%, BB%, 삼진, 승계주자실점률, 볼넷, 사구, 팀 이름 변인들 순으로 나타났으며, 딥러닝은 ERA, OPS, 실책, K%, 삼진, 볼넷, 승계주자실점률, 사구, 홈/어웨이, BB%, 팀 이름 변인들 순으로 나타났다.

또한 승패 상황에 따른 각 변인들의 영향력을 분석한 결과 랜덤포레스트에서는 투수들의 삼진 개수가 많고, 타자들의 출루와 장타 수치가 높은 동시에 볼넷과 사구를 얻는 횟수가 많을수록 팀 승리에 긍정적인 영향을 끼친 반면, 투수들의 볼넷 허용 횟수, 승계주자실점 및 실점이 많고, 타자들의 삼진을 당하는 횟수, 실책 횟수가 많을수록 팀 승리에 부정적인 영향을 끼쳤다.

XGBoost에서는 팀이 어웨이 경기를 치르며, 투수들의 삼진 개수가 많고, 타자들의 출루와 장타 수치가 높으며 볼넷과 사구를 많이 얻을수록 팀 승리에 긍정적인 영향을 끼친 반면, 팀이 홈 경기를 치르며, 투수들의 승계주자실점과 실점이 많고, 타자들의 삼진을 당하는 횟수와 실책 횟수가 많을수록 팀 승리에 부정적인 영향을 끼쳤다.

마지막으로 딥러닝에서는 투수들의 삼진 개수가 많고, 타자들의 출루와 장타의 수치가 높고, 볼넷과 사구를 얻는 횟수가 많을수록 팀 승리에 긍정적인 영향을 끼친 반면, 투수들의 승계주자실점과 실점이 많고, 타자들의 삼진을 당하는 횟수와 실책 횟수가 많을수록 팀 승리에 부정적인 영향을 끼쳤다.

이 연구를 통해 승패 예측에 대한 모델별 예측정확도는 XGBoost, 랜덤포레스트, 딥러닝 순으로 높다는 것을 확인할 수 있었으나, 새로운 데이터에 대한 일반화는 딥러닝, XGBoost, 랜덤포레스트 순으로 높다는 것을 확인할 수 있었다. 또한 XAI를 통해 예측 과정 속에서 각 변인의 중요도와 승패 상황에 따른 각 변인의 영향력이 모델별로 상이하다는 것을 확인할 수 있었다.

이 연구는 기계학습 및 인공지능 모델을 활용하여 야구 승패 예측을 하며, 블랙 박스 인공지능 모델의 단점을 보완하기 위해 XAI를 통해 변인들의 중요도 및 영향력을 분석하여 승패에 따른 상황적 해석을 시도했다는 점에 가치가

있다고 판단된다.

주제어: 야구 경기분석, 기계학습 및 인공지능 모델, 승패 예측, XAI, SHAP



목 차

국문초록	i
목 차	iv
표 목 차	vi
수식목차	vii
그림목차	viii
I. 서론	1
1. 연구의 필요성	1
2. 연구의 목적	5
3. 연구 문제	5
4. 용어의 정의	6
II. 연구 방법	17
1. 연구 대상	17
2. 연구 절차	19
3. 연구 변인	20
4. 자료 수집	22
5. 자료 분석	24

Ⅲ. 연구 결과	35
1. 기술통계 결과	35
2. 기록 변인 선별 결과	38
3. 데이터 표준화 및 전처리 결과	43
4. 기계학습 및 인공지능 모델 예측 결과	45
5. 변인 중요도 및 영향력 분석 결과	54
IV. 논의	63
V. 결론 및 제언	67
1. 결론	67
2. 제언	69
참고문헌	70
Abstract	73

표 목 차

<표 1> 세이버메트릭스 기록	7
<표 2> 연구 대상	18
<표 3> 연구 절차	19
<표 4> 빈도 지표 기록 및 확률 지표 기록	20
<표 5> 연구 변인 구성	21
<표 6> K-fold 교차검증 구현 환경	27
<표 7> Pilot1 평가 모델 구조	31
<표 8> Pilot2 평가 모델 구조	31
<표 9> Pilot3 평가 모델 구조	31
<표 10> 기계학습 및 딥러닝 모델 구현 환경	32
<표 11> 기술통계 결과	36
<표 12> 다중공선성 분석 결과	41
<표 13> 최종 데이터 예시	44
<표 14> 랜덤포레스트 모델 예측정확도(학습용 데이터)	46
<표 15> 랜덤포레스트 모델 예측정확도(평가용 데이터)	46
<표 16> XGBoost 모델 예측정확도(학습용 데이터)	48
<표 17> XGBoost 모델 예측정확도(평가용 데이터)	48
<표 18> 평가 모델 예측정확도	50
<표 19> 딥러닝 모델 예측정확도(학습용 데이터)	52
<표 20> 딥러닝 모델 예측정확도(평가용 데이터)	52

수 식 목 차

<수식 1> 정확도(Accuracy) 산출 공식	14
<수식 2> 정밀도(Precision) 산출 공식	15
<수식 3> 재현도(Recall) 산출 공식	15
<수식 4> F1-Score 산출 공식	16



그 립 목 차

<그림 1> 인공지능, 기계학습, 딥러닝의 관계	8
<그림 2> 인공신경망의 구조	10
<그림 3> 인공신경망과 심층신경망	11
<그림 4> 예측 결과와 실제 정답의 Confusion Matrix	14
<그림 5> KBO 경기 기록 데이터	22
<그림 6> 정제된 경기 기록 데이터	23
<그림 7> K-fold 교차검증 방식	26
<그림 8> 랜덤포레스트 모델 구조	28
<그림 9> XGBoost 모델 구조	29
<그림 10> 활성화 함수	31
<그림 11> SHAP 도식화	33
<그림 12> 상관관계 시각화 그래프	39
<그림 13> 최종 딥러닝 모델 구조	51
<그림 14> 랜덤포레스트 모델 절대적 영향도	54
<그림 15> 랜덤포레스트 모델 긍/부정 영향도	55
<그림 16> XGBoost 모델 절대적 영향도	57
<그림 17> XGBoost 모델 긍/부정 영향도	58
<그림 18> 딥러닝 모델 절대적 영향도	60
<그림 19> 딥러닝 모델 긍/부정 영향도	61

I. 서 론

1. 연구의 필요성

오늘날 스포츠 경기는 대중들의 많은 관심과 호응을 얻고 있고, 경기력 향상에 대한 스포츠 관계자들의 의지가 증가하고 있다(서경화, 2011). 이러한 이유로 눈에 보이지 않는 경기의 내부 요소들을 빅데이터화하고 그 빅데이터를 활용하는 경기력 분석의 중요성과 필요성이 대두되고 있는 추세이다. 이러한 추세에 맞게 경기장 안팎에서는 경기력 향상에 대한 분석이 오래전부터 이루어졌다. 김필수와 이상현(2023)은 4차 산업혁명의 시대가 본격화되어 과학과 기술의 발달로 스포츠 경기에 대한 데이터 자료 수집 및 분석 방법에 과학적인 기술들을 접목한 스포츠 경기 분석이 한 단계 더 발전하고 있다고 설명하였다.

발전하고 있는 경기 분석의 동향 속에서 스포츠 경기의 분석을 더 효과적으로 수행하기 위한 연구들은 꾸준히 진행되고 있다. 국내의 최근 논문들을 살펴보면 프로농구 및 국내 남자 테니스 단식 경기의 데이터를 수집하여 승패 결정 요인과 득점 과정을 분석하는 연구가 진행되었다(김세형, 이준우와 이미숙, 2012; 이기봉, 이영석과 이기청, 2004). 또한 세계스포츠경기력분석학회(International Journal of Performance Analysis in Sport)에서 진행된 해외 연구들을 살펴보면 농구와 테니스뿐만 아니라 세계 시니어 여자배구와 유럽 프로축구에서 팀 성적에 영향을 미치는 변인과 팀 승격 기회 요인을 분석하는 연구들이 진행되었다(Natalia, Vicente와 Paulo Vicente, 2016; Mikael 등, 2021).

빅데이터를 활용한 경기 분석은 축구, 야구, 농구, 배구 등 여러 종목에서 이루어지고 있으며, 우리는 스포츠와 데이터를 서로 떼어낼 수 없는 수어지교의 시대 속에서 살아가고 있다. 최형준(2020)은 빅데이터를 사용한 경기 분석이 어느 때보다도 활발하게 이루어지고 있다고 설명하였고, 조정환(2012)은 스포츠 현장에서 빅데이터를 사용한 경기 분석에 대한 수요가 증가할 것이고 이에 관한 관심도가 계속해서 증대될 것

이라고 예측하였다.

최근에는 기계학습(Machine Learning) 및 인공지능(Artificial Intelligence; 이하 AI) 기법을 사용한 경기 분석 연구들도 진행되면서 스포츠와 데이터를 과학적으로 융합하고 이를 활용할 수 있게 되었다. 최형준(2022)은 스포츠 경기 분석에서 다양한 인공지능 기법들이 적용되어 경기 분석이 진행되고 있다고 언급하며 축구 경기 결과 예측을 위한 머신러닝 기법 비교의 논문을 발표하였다. 또한 최형준과 김주학(2006)은 인공신경망(Artificial Neural Network)을 이용한 2005년도 영국 Wimbleton 테니스 대회 경기 결과 예측 연구의 논문을 발표하였다.

특히 야구에서는 데이터를 활용한 경기 분석이 더욱 활발한데 그 대표적인 예시로 '세이버메트릭스(Sabermetrics)'를 들 수 있다. Baumer현와 Zimbalist(2013)는 세이버메트릭스를 선수들의 경기력과 경기 전략을 분석하기 위한 통계적인 방법들의 사용이라고 설명하였다. '야구는 기록의 스포츠다'(김차용, 2001)라는 말처럼 야구에서는 매우 많은 원자료가 경기 내에서 생성 및 추출되고 빅데이터화 되면서 세이버메트릭스가 활용되게 되었다(권순규, 이규원, 최형준, 2019). 또한 Baumer와 Zimbalist(2013)는 세이버메트릭스가 다년간 쌓인 방대한 야구 선수들의 성적들을 전처리 및 정제하여 경기 기여도의 지표로서 경기 현장에서 사용되고 있고, 방대하게 생성되고만 있었던 선수들의 성적 지표에 대한 객관적인 시선을 갖출 수 있게 도움을 주었다고 언급하였다. 야구에서는 이러한 기록 데이터 및 세이버메트릭스를 활용한 경기 분석이 현재 이루어지고 있는데, 권순규(2017)는 이닝 수, 점수 차, 경기 결과 등을 활용해서 심판 합의 판정의 내용을 분석하였고, Mamiko와 Toshimasa(2022)는 더 좋은 타격을 위한 뜬공과 땅볼에 관한 통계 분석 연구를 하였다.

이 외에도 기계학습 및 인공지능 기법을 활용한 경기 분석에 관한 연구도 진행되고 있는데 이러한 연구들을 살펴보면 인공지능 기반에 따른 한국 프로야구의 승패 예측 분석과 야구 경기 빅데이터에 관한 연구(김종훈, 김경태, 한종기, 2015; 김태훈 등, 2020), K-Means 클러스터링 기법을 이용한 고교야구 타자를 위한 프로야구 선수 지명 예측에 관한 연구(오영환, 2022)들이 프로야구뿐만 아니라 아마추어 야구에서도 여러 방면으로 머신러닝 및 인공지능 기법을 활용하여 경기 분석이 활발하게 이루어지

고 있다. 또한 조선미 등(2023)은 머신러닝 기반 미국프로야구(MLB)의 투구별 안타 및 홈런 예측 모델 개발 연구를 하며 야구에서 수집된 데이터가 복합적으로 활용될 수 있다는 것을 설명하였다. 이렇게 스포츠 경기 분석의 발전에 기여한 연구들이 선행되면서 일반적인 경기 분석뿐만이 아니라 과학적인 기술들을 융합한 데이터 수집과 빅데이터를 활용한 경기 분석들이 많이 이루어지고 있다는 것을 알 수 있다. 최근 야구에서는 주로 승패 예측, 혹은 투구 예측 및 타구 예측 등에 관한 경기 분석이 진행되면서 야구에서의 데이터를 심도 있게 활용할 수 있게 되었다.

야구에서는 어느 종목보다 다양하고 자세한 기록이 존재하고 그 기록을 빅데이터화 하여 경기 분석에 적용하고 있다(황서영, 2006). 과학적인 경기 분석 방법이 사용되는 상황 속에서 수집한 수많은 데이터들 중 어떠한 데이터를 추출하여 사용할 것인지, 그리고 어떠한 데이터가 팀에 얼마나 혹은 어떻게 영향을 끼치는지 알기란 쉽지 않다. 또한 머신러닝 및 인공지능 연구는 주로 경기력에 초점을 맞춘 연구가 진행되고 있어 이를 더 자세히 알 수 없는 실정에 있다(조선미, 2022).

논의한 바와 같이 야구에서는 경기력 측면에 기인한 연구들이 선행되고 있다. 본 연구에서는 야구에서의 경기력과 관련된 경기 승패 예측뿐만 아니라 각 데이터의 중요도를 분석할 수 있는 설명가능한 인공지능(explainable AI; 이하 XAI)을 활용하여 각 지표의 영향력을 분석하고 이를 해석하고자 한다. XAI는 인공지능 기법의 결과 도출 과정에 있어서 불투명한 의사 결정 시스템의 기능을 설명할 수 있는 인공지능 기법이다(염찬욱, 광근창, 2019). 강지연(2022)은 인공지능의 블랙박스 모델의 한계로 인해 예측된 결과에 해석적 접근이 어려웠지만 최근에 여러 XAI 기법들이 나타나면서 그러한 문제점을 어느 정도 극복했다고 언급하였다. 특히 그 중 SHAP(SHapley Additive exPlanation)은 변수 간의 상호 의존성을 고려하여 각 변수의 기여도를 구하는 장점이 있어 이를 통해 야구에 내재되어 있는 수많은 데이터의 복잡한 얽힘을 더욱 효과적으로 해석할 수 있다.

따라서 이 연구에서는 야구에서의 경기 승패의 예측을 위해 인공지능 모델들을 활용하여 얼마나 정확하게 예측하는지를 여러 평가 지표를 통해 비교하는 데 목적이 있다. 또한 수많은 데이터를 SHAP의 장점을 활용하여 효과적으로 경기 승패 예측에 사

용된 변수들의 기여도 및 영향력을 해석하고, 그 지표를 인공지능 모델 간의 차이를 분석하고자 한다.



2. 연구의 목적

본 연구는 한국 프로야구(Korea Baseball Organization; 이하 KBO) 공식 기록을 토대로 기계학습 및 인공지능 모델에 적용하여 경기 승패 예측을 할 때, 얼마나 정확하게 예측하는지를 비교하고자 한다. 또한 설명가능한 인공지능(XAI)을 기반으로 각 변수의 기여도 및 영향력을 해석하고 인공지능 모델 간의 차이를 분석하는 데 목적이 있다.

3. 연구 문제

이 연구에서는 앞서 설정한 연구 목적을 위하여 연구 문제를 다음과 같이 설정하였다.

문제 1. 승패 예측 결과에 대한 평가지표가 인공지능 모델별(Random Forest, XGBoost, Deep Learning)로 차이가 있는가?

문제 2. 승패 예측 과정에서 변인들의 영향력은 인공지능 모델별로 차이가 있는가?

4. 용어의 정의

이 연구에서 사용할 용어의 정의는 다음과 같다.

1) 빈도 지표 기록

본 연구에서 사용할 빈도 지표 기록은 야구에서 어떠한 지표를 비율로 나타낸 기록이 아닌 정수로 나타낸 기록이다. 즉, 타수, 안타, 홈런, 타점, 볼넷, 사구, 득점, 잔루, 삼진, 자책, 승계 주자 실점, 실책 등이 이에 해당한다.

2) 확률 지표 기록

확률 지표 기록은 야구에서 순수 빈도 지표 기록들을 통계적인 방법을 활용하여 융합하고 이를 비율로 나타낸 기록이다. 확률 지표 기록에는 순수 기록인 타율, 평균자책점(ERA)과 세이버메트릭스 기록인 OPS(장타율+출루율), 이닝당 출루 허용률(WHIP), K%, BB%, 승계 주자 실점률(Rel%), 수비율(FPct) 등이 있다. <표 1>은 확률 지표 기록에 포함된 세이버메트릭스 기록을 설명하는 표이다.

표 1. 세이버메트릭스 기록(권순규, 이규원, 최형준, 2019)

구분	설명
SLG	장타율은 1루타, 2루타, 3루타, 홈런에 각각 가중치를 부여하여 타자가 타격을 통해 1타수당 몇 루까지 얻어낼 수 있는가를 의미하는 지표이다.
OBP	출루율은 타자가 안타, 볼넷, 사구를 통해 루에 얼마나 많이 살아서 나갔는가를 의미하는 지표이다.
WHIP	이닝당 출루 허용률은 투수가 피안타, 볼넷으로 1이닝당 얼마나 많은 타자를 출루시켰는가를 의미하는 지표이다.
K%	상대한 타자 수 대비 삼진 개수를 의미하는 지표이다.
BB%	상대한 타자 수 대비 볼넷 개수를 의미하는 지표이다.
Rel%	승계 주자 실점률은 투수가 마운드에 올라왔을 때 이전 투수에게 승계 받은 주자를 실점했는지 안 했는지에 관한 지표이다. 낮을수록 투수들이 자신의 역할을 다하고 그 이닝을 끝마쳤다는 것을 의미한다.
FPct	수비율은 야수가 얼마나 실책 없이 수비했는지를 의미하는 지표이다.

3) 인공지능(Artificial Intelligence; 이하 AI)

인공지능이란 인간의 학습능력, 추론능력, 지각능력을 컴퓨터를 활용해 구현하는 것으로서 인간의 고도의 문제 해결 능력을 가진 인공의 기술이다. 또한 인공지능은 기계학습, 인공신경망, 딥러닝을 전체적으로 포괄하는 개념이다. <그림 1>은 인공지능, 기계학습, 딥러닝의 관계를 도식화.




그림 1. 인공지능, 기계학습, 딥러닝의 관계

4) 기계학습(Machine Learning)

인공지능의 하위 집합으로 통계적인 접근 방법을 사용하여 데이터를 통해 컴퓨터를 인간처럼 학습시켜 스스로 규칙을 생성하게 하고 생성된 규칙을 기반으로 데이터를 분류하거나 결과를 도출하는 데 사용되는 기술이다.

5) 랜덤포레스트 모델(Random Forest)

랜덤포레스트 모델은 의사결정나무(Decision Tree)를 기반으로 한 분류 및 회귀 분석 등에 사용되는 배깅 앙상블(Ensemble) 알고리즘으로, 단일 의사결정나무의 단점을 보완하였다. 다수의 의사결정나무들을 임의로 생성하여 학습시키고 학습된 나무들을 바탕으로 결과를 종합적으로 도출해내는 모델이다.


6) XGBoost 모델(eXtreme Gradient Boosting; 이하 XGBoost)

XGBoost 모델은 의사결정나무 기반의 머신러닝 모델로, 설정한 학습 횟수만큼 다수의 의사결정나무들을 생성하고 이를 순차적으로 학습하게 하여 학습될수록 이전보다 더 나은 결과를 도출해내는 부스팅(Boosting) 앙상블 알고리즘 중의 하나이고 분류 및 회귀 분석에 사용된다.

7) 인공신경망(Artificial Neural Network; 이하 ANN)

인공신경망은 생물의 신경망 특히 뇌를 모방한 구조로 입력층(Input Layer), 은닉층(Hidden Layer), 출력층(Output Layer)으로 구성되어 있다. 각각의 층에서 인공 뉴런(노드)들이 네트워크를 형성하고, 뉴런과 뉴런 사이에는 전기신호를 통해 정보를 전달 및 처리하고 학습하여 뉴런들의 복잡한 결합을 모방한 기계학습 알고리즘들 중 하나이다.

여러 번의 학습 과정을 거치게 되는데 한 번의 학습 과정에서 입력층에서 데이터의 입력 신호를 받아 은닉층의 노드들로 그 신호를 전달하고 전달된 신호는 각 노드 안에서 가중치(weights)와 곱해진 후 활성화 함수(Activation Function)를 통과하면서 신호값을 생성한다. 그후 생성된 신호값은 출력층의 노드로 전달되어 결과값을 도출하게 된다. <그림 2>는 인공신경망의 구조를 나타낸 것이다.



- X1 ~ X3: 입력 데이터
- W1, W2: 가중치
- f : 활성화 함수
- Y1 ~ Y3: 출력값

그림 2. 인공신경망의 구조

8) 딥러닝(Deep Learning)

딥러닝은 인공신경망을 기계학습에 적용한 인공지능 기술이다. 또한 인공신경망의 은닉층을 겹겹이 쌓인 복잡한 구조로 구성하여 심층신경망(Deep Neural Network; 이하 DNN) 딥러닝에 사용할 경우 인공신경망보다 더욱 복잡한 문제들을 해결할 수 있는 능력이 함양된다. <그림 3>은 인공신경망과 심층신경망 구조의 차이를 도식화한 것이다.




그림 3. 인공신경망과 심층신경망

9) 설명가능한 인공지능(eXplainable AI; 이하 XAI)

일반적인 인공지능은 데이터를 통해 학습 후 예측 결과를 도출하는 복잡한 작업에는 효율적일 수는 있으나 그 과정의 해석이 부족하다. XAI는 이전에 학습 후 예측 결과값만을 도출하고 의사 결정 과정을 알기 어려운 블랙 박스 모델의 인공지능에서 왜 그런 결과값이 도출되었는지를 각 변인의 중요도와 영향력을 통해 해석 및 설명해주는 인공지능 알고리즘이다(강지연, 2022).

XAI 기법에는 여러 종류가 있는데 대표적으로 SHAP, PDP, LIME 등이 있다. 본 연구에서는 SHAP(SHapley Additive exPlanation)기법을 사용하여 인공지능 모델의 예측 과정 속에서 각 변인의 중요도와 영향력을 분석하고자 한다.

10) 데이터 표준화(Standardization of Data Preprocessing)

데이터 표준화는 데이터 전처리 과정 중 하나로, 수집된 로우데이터가 각각의 상이한 범위와 서로 다른 단위로 인해 상호 비교하는데 부적절하기 때문에 상호 비교가 가능하도록 로우데이터를 평균으로부터 얼마큼 떨어져 있는지를 나타내는 값인 표준점수로 변환하는 작업이다.

11) 데이터 정규화(Normalization of Data Preprocessing)

데이터 정규화는 데이터 전처리 과정 중 하나로, 수집된 로우데이터의 값들을 0과 1사이의 범위로 이동하고 재조정하는 작업이다.

12) 원-핫 인코딩(One-hot encoding)

원-핫 인코딩은 데이터 전처리 과정 중 하나로, 연속형이 아닌 범주형 변수를 컴퓨터가 이해할 수 있도록 범주형 변수의 개수만큼 열을 생성하여 그 변수의 고유값에 해당하는 열에 1을 부여하고 나머지 열에는 0을 부여하여 구별이 가능하도록 하는 작업이다.

13) 과적합(Overfitting)

과적합은 기계학습 및 인공지능 모델이 학습용 데이터에만 과도하게 적합하게 되어 평가용 데이터에서의 예측 성능이 떨어지는 것을 의미한다. 이는 모델이 너무 복잡하게 구성된 경우, 학습 횟수가 데이터의 구성에 비해 매우 많을 경우, 그리고 학습 데이터가 매우 적을 경우 발생하는 현상이다.

14) 일반화(Generalization)

일반화는 학습용 데이터로 학습된 기계학습 및 인공지능 모델이 학습용 데이터에만 과도하게 적합한 것이 아니라 새로운 데이터인 평가용 데이터에도 예측 성능이 뛰어난 것을 의미한다. 이는 데이터의 수, 혹은 변인의 수에 맞게 모델의 구조와 학습 횟수가 올바르게 설정되어 있을 때 이루어진다.

15) 교차검증(Cross Validation)

교차검증은 데이터를 정해진 횟수만큼 반복해서 분할하고 학습하여 예측 성능을 평가하는 방법으로 기계학습 및 인공지능 모델 학습 후 거쳐야 하는 가장 중요한 평가 과정 중 하나이다.

본 연구에서는 교차검증 방법 중 하나인 K-fold 교차검증 방법을 활용할 것이고, K-fold 교차검증은 전체 데이터를 k개로 분할한 후 k-1개를 학습용 데이터로, 1개를 평가용 데이터로 임의로 분할하여 k번만큼 교차검증을 수행한다. 이는 학습용 데이터와 평가용 데이터가 불균등하게 분할되어 과적합 될 가능성을 감소시켜준다.

16) 정확도(Accuracy Score)

정확도는 말 그대로 얼마나 정확하게 예측했느냐를 측정하는 지표로, 전체 데이터 수 중 정확하게 예측한 결과값과 실제 결과값이 동일한 경우의 비율을 의미하는 기계학습 및 인공지능 분류 모델의 평가 지표 중 하나이다.

$$Accuracy = \frac{TP + TN}{TP + TN + FN + FP}$$

수식 1. 정확도(Accuracy) 산출 공식

		실제 정답	
		Positive (1)	Negative (0)
예측 결과	Positive (1)	True Positive (TP)	False Positive (FP)
	Negative (0)	False Negative (FN)	True Negative (TN)

그림 4. 예측 결과와 실제 정답의 Confusion Matrix
(Khan & Kirubanand, 2019)

<그림 4>는 모델이 예측해서 분류된 결과와 실제 정답의 관계 속에서 도출되는 요소들의 Confusion Matrix이다.

- True Positive(TP): 실제 1인 정답을 1로 예측한 경우(정답)
- True Negative(TN): 실제 0인 정답을 0으로 예측한 경우(정답)
- False Negative(FN): 실제 1인 정답을 0으로 예측한 경우(오답)
- False Positive(FP): 실제 0인 정답을 1로 예측한 경우(오답)

17) 정밀도(Precision Score)

정밀도는 예측 결과가 얼마나 정확한지를 의미하는 측정치로, Positive으로 예측한 경우의 수 중 정확하게 예측한 경우의 비율을 의미하는 기계학습 및 인공지능 분류 모델의 평가 지표 중 하나이다.

$$Precision = \frac{TP}{TP + FP}$$

수식 2. 정밀도(Precision) 산출 공식

- True Positive(TP): 실제 1인 정답을 1로 예측한 경우(정답)
- False Positive(FP): 실제 0인 정답을 1로 예측한 경우(오답)

18) 재현도(Recall Score)

재현도는 실제 Positive인 정답의 경우의 수 중 정확하게 예측한 경우의 비율을 의미하는 기계학습 및 인공지능 분류 모델의 평가 지표중 하나이다.

$$Recall = \frac{TP}{TP + FN}$$

수식 3. 재현도(Recall) 산출 공식

- True Positive(TP): 실제 1인 정답을 1로 예측한 경우(정답)
- False Negative(FN): 실제 1인 정답을 0으로 예측한 경우(오답)

19) F1-Score

F1-Score는 기계학습 및 인공지능 분류 모델의 평가 지표 중 하나로, 값이 클수록 정확하게 예측했다는 의미이며 정밀도(Precision)와 재현도(Recall)의 조화평균 값이다.

$$F1 = \frac{2}{\frac{1}{Recall} + \frac{1}{Precision}} = 2 \times \frac{Precision \times Recall}{Precision + Recall}$$

수식 4. F1-Score 산출 공식

II. 연구 방법

1. 연구 대상

한국 프로야구(KBO) 정규 리그는 10개 팀들이 매년 팀 간 16차전, 팀당 144경기씩 총 720경기를 하고, 2019년 무승부 경기는 7경기, 2020년 무승부 경기는 13경기, 2021년 무승부 경기는 50경기, 2022년 무승부 경기는 12경기, 2023년 무승부 경기는 12경기로 5년 동안의 무승부 경기는 총 94경기였다.

본 연구에서는 2019년, 2020년, 2021년, 2022년, 2023년 5년 동안 진행된 한국 프로야구(KBO) 정규 리그 경기들을 연구 대상으로 설정하였고, 총 3,600경기에서 2019년~2023년 무승부 94경기들을 제외하였다. 무승부 경기들을 제외한 이유는 다중분류보다는 이진분류로 승패만을 예측함으로써 인공지능의 예측 결과 성능을 향상시키기 위해 무승부 경기들은 제외하였다.

또한 2022년 시즌부터 SK 와이번스가 인수되어 SSG 랜더스로 구단 명칭이 변경되었으므로 2019년과 2020년 시즌까지 있었던 SK는 SSG와 동일 연구 대상으로 설정하였다. <표 2>는 연구 대상이 되는 팀과 경기 수를 정리한 표이다.

표 2. 연구 대상

연도(년)	팀	정규 리그 경기 수	무승부 경기 수	연구 대상 경기 수
2019	두산, 키움, SK, LG, NC, KT, KIA, 삼성, 한화, 롯데	720	7	713
2020	NC, 두산, KT, LG, 키움, KIA, 롯데, 삼성, SK, 한화	720	13	707
2021	KT, 두산, 삼성, LG, 키움, SSG, NC, 롯데, KIA, 한화	720	50	670
2022	SSG, 키움, LG, KT, KIA, NC, 삼성, 롯데, 두산, 한화	720	12	708
2023	LG, KT, SSG, NC, 두산, KIA, 롯데, 삼성, 한화, 키움	720	12	708
총계		3,600	94	3,506

2. 연구 절차

본 연구의 연구 절차는 다음과 같다.

표 3. 연구 절차

연구 계획 및 연구 문제 수립	연구에 활용할 인공지능 모델 선택과 연구 주제 선정
2023년 8월	
▼	
연구 대상 및 분석 절차 설정	데이터 수집이 가능한 KBO 공식 기록 홈페이지 탐색
KBO 정규 리그 5년 경기 기록 데이터	
▼	
자료 수집 및 분석	자료 수집 후 인공지능 모델을 활용한 승패 예측 분석
2023년 11월 ~ 12월	
▼	
결과 해석 및 논문 작성	승패 예측 분석 진행 후 분석 결과 해석 진행
2024년 1월 ~	

3. 연구 변인

본 연구에서는 빈도 지표 기록 및 확률 지표 기록을 이용해서 승패 예측을 하고 이를 비교 및 분석하고자 한다. 각 기록은 KBO 기록 홈페이지(www.statiz.co.kr)에서 제공하는 2019년, 2020년, 2021년, 2022년, 2023년 정규 리그 내 각 경기당 홈팀과 원정팀의 기록을 사용하였다.

첫 번째 빈도 지표 기록은 타수, 안타, 홈런, 타점, 볼넷, 사구, 득점, 잔루, 삼진, 자책, 승계 주자 실점, 실책 등 12개의 독립변인으로 구성할 것이고, 두 번째 확률 지표 기록은 타율, OPS(장타율+출루율), 평균자책점(ERA), 이닝당 출루 허용률(WHIP), K%, BB%, 승계 주자 실점률(Rel%), 수비율(FPct) 등 8개의 독립변인으로 구성하였다. 따라서 빈도 지표 기록과 확률 지표 기록을 합한 기록은 총 20개이며, 여기에 홈/어웨이, 팀 이름을 추가하여 총 22개의 독립변인으로 구성하였다. 또한 종속변인은 각 승패 예측마다 승패 1개로 설정하였다. <표 4>는 빈도 지표 기록과 확률 지표 기록의 표이고, <표 5>는 연구 변인 구성에 대한 표이다.

표 4. 빈도 지표 기록 및 확률 지표 기록

구분	구성
빈도 지표 기록	타수, 안타, 홈런, 타점, 볼넷, 사구, 득점, 잔루, 삼진, 자책, 승계 주자 실점, 실책
확률 지표 기록	타율, OPS(장타율+출루율), 이닝당 출루 허용률(WHIP), 평균자책점(ERA), K%, BB%, 승계 주자 실점률(Rel%), 수비율(FPct)

표 5. 연구 변인 구성

구분	변인
독립변인	빈도 지표 기록 + 확률 지표 기록 + 홈/어웨이, 팀 이름
종속변인	승패

4. 자료 수집

본 연구의 자료는 인터넷을 통해 KBO 기록 홈페이지에 있는 경기 기록 데이터를 Microsoft Visual Basic for Applications(VBA) 7.1을 통해 수집하고, 수집한 데이터를 Microsoft Excel 365를 통해 정제하였다. <그림 5>와 <그림 6>은 KBO 기록 데이터와 정제된 데이터의 일부이다.

타순	이름	Pos.	PA	AB	R	H	HR	RBI	BB	HBP	SO	GO	FO	NP	GDP	LOB	AVG	OPS	LI	WPA	RE24
1	정수빈	CF	5	5	0	0	0	0	0	0	2	2	1	25	0	2	0.252	0.698	0.70	-0.035	-0.62
2	박계범	SS	5	5	1	2	0	0	0	0	1	2	0	12	0	2	0.308	0.629	0.79	-0.088	-0.71
3	양희지	C	5	5	2	2	1	1	0	0	2	0	1	22	0	1	0.277	0.812	0.62	0.133	0.90
4	양석환	DH	5	5	1	2	1	2	0	0	2	1	0	19	0	0	0.295	0.848	0.83	0.146	1.13
	전민재	PR,DH	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0.250	0.500	0.00	0.000	0.00
5	허경민	3B	5	4	0	3	0	1	0	1	0	1	0	18	0	0	0.310	0.819	0.63	0.100	1.89
6	로하스	LF	4	3	0	1	0	0	0	1	0	2	0	9	0	1	0.200	0.713	0.83	0.035	0.60
	조수형	P,R,L,F,R,F	1	1	0	0	0	0	0	0	0	1	0	4	0	2	0.182	0.544	0.30	-0.009	-0.63
7	김민혁	1B	3	3	0	0	0	0	0	0	1	1	1	9	0	3	0.083	0.381	1.33	-0.092	-1.07
	김재환	PH	1	1	0	0	0	0	0	0	0	0	1	3	0	2	0.255	0.761	1.02	-0.023	-0.49
	강승호	1B	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0.255	0.604	0.00	0.000	0.00
8	양찬열	R,F,L,F	4	2	0	1	0	0	2	0	0	1	0	24	0	2	0.294	0.704	1.16	-0.003	0.34
9	이유찬	2B	4	4	0	0	0	0	0	0	1	2	1	11	0	6	0.228	0.565	1.30	-0.133	-2.05
팀 합계			42	38	4	11	2	4	2	2	9	13	5	156	0	21	0.289	0.831	2.38	0.031	-0.71

그림 5. KBO 경기 기록 데이터

번호	팀이름	홈/어웨이	타수	득점	안타	홈런	타점	사사구	사구	삼진	찬루	자책	승계주자실점	실책	승1패0
1	롯데	어웨이	36	7	9	0	6	4	0	11	19	2	0	0	1
2	키움	홈	36	2	9	0	2	3	0	11	20	3	0	1	0
3	한화	어웨이	36	4	10	0	4	5	0	11	21	5	0	2	0
4	두산	홈	32	6	9	1	6	3	0	4	15	4	0	1	1
5	SSG	어웨이	36	4	8	0	4	3	1	8	13	0	0	0	1
6	NC	홈	30	0	0	0	0	1	0	11	1	4	3	0	0
7	LG	어웨이	33	9	6	1	9	3	2	10	11	0	0	0	1
8	KIA	홈	29	0	3	0	0	3	2	10	13	5	0	3	0
9	삼성	어웨이	29	1	2	0	1	1	0	5	7	4	0	0	0
10	KT	홈	32	4	11	0	4	5	0	4	23	1	0	0	1
11	롯데	어웨이	40	3	12	0	3	1	1	8	19	4	1	0	0
12	키움	홈	37	4	9	0	4	4	0	7	15	3	0	1	1
13	한화	어웨이	31	0	3	0	0	0	0	8	6	1	0	0	0
14	두산	홈	29	1	7	1	1	1	0	9	13	0	0	1	1
15	SSG	어웨이	31	4	7	3	4	3	0	8	11	1	0	0	1
16	NC	홈	31	1	5	0	1	3	0	10	19	3	1	1	0
17	LG	어웨이	34	3	10	0	3	1	1	15	11	2	0	0	1
18	KIA	홈	36	2	10	1	2	6	0	6	21	3	0	0	0
19	삼성	어웨이	38	6	11	0	6	0	0	5	15	5	1	1	1
20	KT	홈	34	5	8	1	4	5	1	10	21	5	2	1	0
21	LG	어웨이	38	8	12	1	8	2	0	2	18	4	0	1	1
22	키움	홈	33	4	5	1	3	4	1	12	14	5	0	1	0
23	삼성	어웨이	29	6	6	1	6	7	1	6	16	4	1	2	1
24	두산	홈	37	5	11	1	4	1	0	9	19	5	1	2	0
25	롯데	어웨이	36	5	12	1	5	4	1	6	27	1	0	1	1

그림 6. 정제된 경기 기록 데이터

5. 자료 분석

본 연구에서는 먼저 수집한 데이터를 전처리하고 기술 통계 결과를 도출하였다. 그 후 수집한 데이터를 표준화 및 정규화하고, 다중공선성을 살펴서 22개의 독립변인들 중 다중공선성의 문제가 있는 독립변인들을 제거한 후 승패 예측 분석에 사용될 독립변인들을 선별하였다. 그리고 선별된 독립변인들로 기계학습 및 인공지능 모델을 활용한 승패 예측을 K-Fold 교차검증을 통해 진행하였다. 마지막으로 설명가능한 인공지능(XAI)을 사용하여 각 변인의 기여도를 분석하였다.

본 연구의 자료 분석은 Python 3.10.12를 통해 이루어지며, 자료 분석 절차의 세부적인 내용은 다음과 같다.

1) 데이터 전처리

데이터를 수집한 후 수집된 데이터에서 명명척도 변인인 승패를 1과 0으로 처리하였고, 각 경기당 팀 기록에 차례대로 번호를 부여하였다. 또한 팀 이름은 원-هاب 인코딩을 통해 기계학습 및 인공지능 모델이 예측하기 용이하도록 전처리하였다.

2) 기술 통계

수집된 각 경기 데이터를 통해 기록의 전체적인 평균, 분산, 빈도 등을 알기 위하여 Python의 Pandas 2.0.2 버전 모듈을 사용하여 기술 통계 분석하였다.

3) 표준화

데이터 표준화를 통해 원자료의 상이한 범위와 서로 다른 단위로 인한 상호 비교의 어려움을 해결하고, 각 기록의 광범위한 범위를 감소시켜서 기계학습 및 인공지능 모델의 예측이 용이하도록 하였다.

4) 기록 변인 선별

(1) 상관관계 분석

기계학습 및 인공지능 모델 학습 과정 중 변인 간 연관성이 너무 높아 예측에 오류가 생기는 경우가 있다. 이를 피하기 위해 먼저 기록 변인들 간 상관관계 분석을 진행한다. 본 연구에서는 피어슨의 적률상관계수를 사용하여 상관관계 분석을 진행하였다.

(2) 다중공선성

다중공선성은 독립변인 간 상관관계가 높아 기계학습 및 인공지능 기법을 활용한 예측 분석에 부정적인 영향을 끼치는 것을 의미한다. 다중공선성은 분산팽창요인 계수(VIF Factor)를 통해 평가할 수 있으며 그 계수가 10 이상이면 다중공선성의 문제가 발생했다고 판단한다. 다중공선성을 살펴봄으로써 여러 변인 간의 상관성을 고려했을 때 어떤 변인을 제거하는 것이 좋을지 혹은 제거를 안 하는 것이 좋을지를 판단하는 기준을 세울 수 있다. 따라서 위 내용을 바탕으로 승패 예측 분석에 사용될 기록 변인들 중 다중공선성의 문제가 있는 변인들을 제거한 후 기계학습 및 인공지능 모델을 통한 승패 예측 분석하였다.

5) K-fold 교차검증(K-fold Cross Validation)

K-fold 교차검증은 기계학습 및 인공지능 모델을 학습시킨 후 예측 성능을 평가했을 때 고정된 학습용 데이터와 평가용 데이터로 불균등하게 분할되어 과적합되는 현상을 예방하기 위한 교차검증의 한 방법이다. 모델 학습을 하기 전에 전체 데이터를 k개로 분할한 후 k-1개를 학습용 데이터로, 나머지 1개를 평가용 데이터로 임의로 분할한다. 그 후 임의로 분할된 학습용 데이터로 학습시키며 학습용 데이터에 대한 평가 지표를 도출하고, 학습된 모델을 통해 평가용 데이터에 대한 평가 지표 또한 도출하며 이를 k번만큼 반복 수행한다.

본 연구에서 데이터 분할 및 교차검증 반복 횟수는 5번으로 k=5로 설정할 것이며, 제시할 평가 지표는 정확도(Accuracy Score), 정밀도(Precision Score), 재현도(Recall Score), F1-Score이다. 또한 K-fold 교차검증은 <그림 7>과 같이 진행된다.

	전체 데이터				
반복 1	Test	Train	Train	Train	Train
반복 2	Train	Test	Train	Train	Train
반복 3	Train	Train	Test	Train	Train
반복 4	Train	Train	Train	Test	Train
반복 5	Train	Train	Train	Train	Test

그림 7. K-fold 교차검증 방식

본 연구에서 구현할 K-fold 교차검증 환경은 <표 6>과 같다.

표 6. K-fold 교차검증 구현 환경

사용 패키지	사용 모듈	사용 클래스
scikit-learn 1.2.2	model_selection	KFold

6) 기계학습 및 인공지능 모델

(1) 랜덤포레스트 모델(Random Forest)

랜덤포레스트 모델은 배깅(Bagging) 앙상블 알고리즘의 하나로, 의사결정나무(Decision Tree)를 기반으로 한 분류 및 회귀 분석 등에 사용된다. 서로 독립적인 의사결정나무들을 임의로 생성하여 하나의 숲을 구성하는 형태를 띠고 있고, 다수의 의사결정나무를 학습시킨 후 각 나무에서 도출되는 결과값들의 평균치(회귀) 혹은 집계된 분류값들의 최빈치(분류)를 통해 예측을 수행한다. 또한 의사결정나무들을 종합하여 예측을 수행함으로써 단일의 의사결정나무에서 도출되는 예측값보다 더 정확한 성능을 보인다.

본 연구에서는 랜덤포레스트 모델의 `n_estimators` 하이퍼 파라미터를 200으로 설정하여 200개의 의사결정나무들을 통해 승패의 분류에 대한 예측을 수행하였다. <그림 8>은 랜덤포레스트 모델 구조에 대한 도식화이다.




그림 8. 랜덤포레스트 모델 구조
(Nguyen, Wang & Nguyen, 2013)

(2) XGBoost 모델(eXtreme Gradient Boosting; 이하 XGBoost)

XGBoost 모델은 다수의 의사결정나무들을 순차적으로 학습하게 하여 학습될수록 이 전보다 향상된 결과를 도출해내는 의사결정나무 기반의 부스팅(Boosting) 앙상블 알고리즘 중 하나이다. 학습이 진행될수록 실제 정답과 예측 결과에 대한 오차 및 오류의 최소 지점을 찾아나가며 가중치를 부여하고, 예측 정확성이 떨어지는 모형에 대해선 가중치를 더 부여하여 향상된 결과를 도출해낸다. 또한 XGBoost 모델은 병렬 처리로 학습을 하여 학습 속도뿐만 아니라 예측 속도도 빨라 분류 및 회귀 분석에 있어서 높은 성능을 보인다.

본 연구에서는 XGBoost 모델의 `n_estimators` 하이퍼 파라미터를 200으로 설정하여 200개의 의사결정나무들을 통해 승패의 분류에 대한 예측을 수행하였다. <그림 9>는 XGBoost 모델 구조에 대한 도식화이다.




그림 9. XGBoost 모델 구조
(Chen & Guestrin, 2016)

(3) 딥러닝(Deep Learning)

딥러닝은 입력층(input layer), 은닉층(hidden layer), 출력층(output layer)로 구성되어 생물의 복잡한 뉴런의 구조를 모방한 인공신경망에서 은닉층의 개수를 증가시킨 심층신경망을 활용하여 인공신경망보다 더욱 복잡한 문제를 해결하고 더 좋은 결과값을 도출해내는 기계학습 인공지능 기술이다. 입력층에서 입력 신호를 받아 이를 가중치와 곱하여 은닉층으로 보내고, 입력 신호를 받은 은닉층에서는 그 신호를 활성화 함수(Activation Function)에 통과시켜 출력층으로 전달한다. 은닉층의 신호를 받은 출력층은 이를 출력층의 활성화 함수를 통해 0~1의 확률값으로 결과를 도출해낸다. 이러한 과정 속에서 딥러닝은 실제 정답과 예측 결과의 최소 오차값을 구하기 위해 학습을 진행하고, 또한 오차가 최소가 되도록 하는 최적의 가중치를 찾아나가며 모델을 업데이트시킨다.

딥러닝 모델의 구조 및 하이퍼 파라미터는 대체로 연구자의 경험을 바탕으로 설정되고 평가된다(조억, 김성범, 2020). 따라서 인공지능 모델의 구조를 최적화하기 위해 다양한 모델들을 구축한 후 그 모델들을 통해 반복 실험을 수행하여야 한다(김주학, 조선미, 강지연, 2022).

본 연구에서는 딥러닝 모델의 구조를 최적화하기 위해 3개의 평가 모델을 구축한 후 전체 7,012개의 기록 데이터에서 20%를 무작위 추출한 1,402개의 기록 데이터를 각각의 모델에 학습시켜 승패 분류에 대한 예측을 정확도(Accuracy Score)로 평가하였다. 각 모델은 Pilot1, Pilot2, Pilot3로 명명할 것이며, 모델들의 입력층의 노드 수는 선별된 독립변인 수로 설정하였다. 그리고 각 모델의 은닉층과 출력층의 구조는 Pilot1은 28-1, Pilot2은 24-1, Pilot3은 17-1로 구축하였다. 또한 각 모델의 학습 반복 횟수는 200으로 동일하며, 활성화 함수는 은닉층에서는 ReLU, 출력층에서는 Sigmoid를 동일하게 사용하였다. 각 평가 모델의 세부 구조는 <표 7>, <표 8>, <표 9>와 같고, 활성화 함수 그래프는 <그림 10>과 같다.

표 7. Pilot1 평가 모델 구조

모델	노드수			학습 반복횟수
	입력층	은닉층	출력층	
Pilot1	선별 독립변인 수	15+9+4=28	1	200

표 8. Pilot2 평가 모델 구조

모델	노드수			학습 반복횟수
	입력층	은닉층	출력층	
Pilot2	선별 독립변인 수	15+9=24	1	200

표 9. Pilot3 평가 모델 구조

모델	노드수			학습 반복횟수
	입력층	은닉층	출력층	
Pilot3	선별 독립변인 수	12+5=17	1	200




그림 10. 활성화 함수

최종적으로 본 연구에서 사용할 딥러닝 모델은 각 평가 모델별 승패 분류 예측에 대한 정확도가 가장 높은 평가 모델의 구조를 채택하였다.

본 연구에서 구현할 기계학습 및 인공지능 모델 환경은 <표 10>과 같다.

표 10. 기계학습 및 딥러닝 모델 구현 환경

언어	모델 구분	사용 패키지	사용 모듈	사용 클래스
Python 3.10.12	랜덤포레스트	scikit-learn 1.2.2	ensemble	RandomForestClassifier
	XGBoost	xgboost 2.0.3	XGBClassifier	X
	딥러닝	Tensorflow 2.15.0	models, layers	Input, Dense, Model

7) 설명가능한 인공지능(eXplainable AI; 이하 XAI)

보통의 인공지능은 복잡한 모델의 구조로 인해 예측 과정에서 ‘왜 이러한 결과가 나왔는가?’에 대한 질문에 답을 하지 못하는 블랙박스 모델의 단점을 갖고 있다. 설명가능한 인공지능(XAI)은 의사 결정 과정에 대한 해석이 없는 블랙 박스 모델 인공지능의 단점을 보완한 인공지능이다. 모델의 예측 과정에 있어 각 변인의 중요도와 영향력을 통해 왜 그런 결과가 나왔는지에 대한 해석 및 설명이 가능하다(강지연, 2022).

현재 XAI 기법에는 여러 종류가 있는데 대표적으로 SHAP, PDP, LIME 등이 있다. 본 연구에서는 SHAP(SHapley Additive exPlanation)을 활용하여 각 인공지능 모델의 예측 과정을 해석하고자 한다.



그림 11. SHAP 도식화

SHAP은 각 플레이어의 기여도에 따라 상금을 공정하게 분배하기 위한 게임이론 (Game Theory)에 기반을 두고 있으며, 각 플레이어가 있을 때와 없을 때의 차이를 비교하며 그 기여도를 계산한다. SHAP은 그 기여도를 Shapley value를 통해 예측 결과값에 대한 각 변인의 기여도를 측정함으로써 그 변인의 중요도와 영향력을 분석한다. 본 연구에서는 Global SHAP를 통해 각 변인에 대한 전체 데이터의 공/부정 영향도를 살펴보고, SHAP의 절대적 영향도를 도출하여 변인들의 중요도를 분석한다.

또한 SHAP은 Tree SHAP, Deep SHAP으로 나누어져 있어 의사결정나무 계열 기

반 Shapley value와 딥러닝 기반 Shapley value를 구현할 알고리즘의 구조에 맞게 도출해낼 수 있다. 본 연구에서는 랜덤포레스트 모델과 XGBoost 모델은 의사결정나무 기반 모델이므로 Tree SHAP를 사용할 것이고, 딥러닝 모델은 Deep SHAP를 사용하여 각 변인의 중요도와 영향력을 분석 및 예측 과정을 해석하고자 한다.



Ⅲ. 연구 결과

이 연구는 2019년, 2020년, 2021년, 2022년, 2023년 한국 프로야구(KBO) 정규리그 경기의 팀 기록을 기계학습 및 인공지능 모델에 따른 승패 예측 모델을 설계하고, 예측값들에 따른 예측정확도 평가지표들을 통해 모델별로 얼마나 정확하게 예측하였는지 분석하였다. 또한 설명가능한 인공지능(XAI)을 활용하여 각 모델에 대한 승패 예측 과정에서의 변인들의 중요도 및 영향력을 파악하였으며 도출된 결과는 다음과 같다.

1. 기술통계 결과

수집된 기록 데이터의 특성을 파악하기 위해 독립변인들의 기술통계를 실시하였고, 기술통계는 2019년, 2020년, 2021년, 2022년, 2023년 5시즌 동안 무승부 경기를 제외한 KBO 정규리그 경기들에서 기록된 팀 합계 기록 데이터로 실시하였다. 결과는 <표 11>과 같다.

표 11. 기술통계 결과

변인	평균	표준편차	최소값	최대값
타수	34.051	3.991	15	52
득점	4.739	3.445	0	26
안타	9.033	3.613	0	27
홈런	0.772	0.956	0	8
타점	4.460	3.314	0	26
볼넷	3.596	2.230	0	16
사구	0.502	0.738	0	5
삼진	6.925	2.706	0	17
잔루	16.161	5.853	1	43
자책	4.277	3.242	0	24
승계주자실점	0.677	1.118	0	10
실책	0.727	0.881	0	5
타율	0.259	0.082	0	0.533
OPS	0.711	0.221	0.032	1.604
승계주자실점률	0.219	0.341	0	1
ERA	4.424	3.435	0	24.750
WHIP	1.438	0.540	0.100	4
K%	0.181	0.075	0	0.533
BB%	0.090	0.051	0	0.304
수비율	0.981	0.023	0.853	1

빈도 지표 기록에서 팀 합계 타수는 평균 34.051타수(SD=3.991)로 나타났고, 최소값 15타수와 최대값 54타수로 다른 변인들의 범위보다 더 큰 차이가 나는 것을 확인할 수 있었다. 최소값이 이렇게 작은 수치를 나타내는 이유는 우천으로 인한 강우 콜드 경기가 발생하였기 때문이다. 득점은 평균 4.739점(SD=3.445)으로 나타났고, 안타와 홈런은 평균 9.033개(SD=3.613), 평균 0.772개(SD=0.956)로 나타났다. 타점은 득점과 연관이 있는 기록으로서 평균 4.460개(SD=3.314)로 득점의 평균과 비슷한 수치를 나타냈다. 그밖에 볼넷, 사구, 삼진, 잔루, 자책, 승계주자실점, 실책은 각각 평균 3.596개(SD=2.230), 평균 0.502개(SD=0.738), 평균 6.925개(SD=2.706), 평균 16.161개(SD=5.853), 평균 4.277점(SD=3.242), 평균 0.677점(SD=1.118), 평균 0.727개(SD=3.341), 평균 0.727개(SD=0.881)

로 나타났다.

확률 지표 기록에서 팀 합계 타율은 평균 0.259(SD=0.082)로 나타났고, OPS는 평균 0.711(SD=0.221)로 나타났다. 승계주자실점률은 평균 0.219(SD=0.341), ERA는 평균 4.424(SD=3.435), WHIP는 평균 1.438(SD=0.540)로 나타났고, 그 밖에 K%, BB%, 수비율은 각각 평균 0.181(SD=0.075), 평균 0.090(SD=0.051), 평균 0.981(SD=0.023)으로 나타났다.

각각의 변인들은 단위 및 범위가 다양하므로 데이터를 정규분포화 하는 표준화 단계를 거친 뒤 기계학습 및 인공지능 모델로 분석하는 것이 예측률을 높일 수 있다.



2. 기록 변인 선별 결과

기계학습 및 인공지능 모델에 데이터를 학습시켜 승패 분류 예측을 하기 전 기록 변인들 간의 상관관계와 다중공선성을 분석하고 그 수치가 높은 변인들을 제거하여 최종 변인들을 선별하였다. 기록 변인들 간의 상관성이 높으면 기계학습 및 인공지능 모델의 복잡도를 증가시켜 부정적인 영향을 끼치고 예측률을 감소시킬 수 있다. 따라서 예측률을 증가시키기 위해 상관관계 분석 및 다중공선성 분석 과정을 거치고 일부 변인들을 제거해야 한다. 다음은 상관관계 분석 및 다중공선성 분석을 하여 최종 기록 변인들을 선별한 결과이다.

1) 상관관계 분석 결과

기록 변인들 간의 상관관계를 분석하기 위해 상관 분석을 하였으며, <그림 12>는 상관관계를 시각화한 그래프이다.




그림 12. 상관관계 시각화 그래프

위의 상관관계 시각화 그래프를 관찰하였을 때 서로 높은 상관관계를 보이는 기록 변인들을 발견할 수 있었다. 타수 변인과 안타 변인($r=0.80$), 득점 변인과 안타 변인($r=0.78$), 득점 변인과 타점 변인($r=0.99$), 득점 변인과 OPS 변인($r=0.83$), 안타 변인과 타점 변인($r=0.78$), 안타 변인과 타율 변인($r=0.96$), 안타 변인과 OPS 변인($r=0.87$), 타점 변인과 OPS 변인($r=0.84$), 자책 변인과 ERA 변인($r=0.99$), 자책 변인과 WHIP 변

인($r=0.82$), 승계주자실점 변인과 승계주자실점률 변인($r=0.79$), 실책 변인과 수비율 변인($r=-0.99$), 타율 변인과 OPS 변인($r=0.91$), ERA 변인과 WHIP 변인($r=0.82$)들이 높은 상관관계를 나타냈다. 이렇게 높은 상관관계를 보이는 경우 한 변인이 다른 변인을 대체할 수 있기 때문에 둘 중에 한 변인을 제거하였다.

2) 다중공선성 분석 결과

앞서 상관관계 분석을 한 결과를 바탕으로 다중공선성 분석을 하여 모든 기록 변인들의 분산팽창요인 계수를 관찰하였고, 여러 번의 관찰을 통해 승패 분류 예측에 사용될 변인들을 선별해 나갔다. <표 12>는 다중공선성 분석 결과이다.

표 12. 다중공선성 분석 결과

변인	VIF(1차)	변인 선택	VIF(2차)	변인 선택	최종 VIF
타수	968.19	X	-	-	-
득점	113.87	X	-	-	-
안타	762.40	X	-	-	-
홈런	7.92	O	3.05	X	-
타점	113.27	X	-	-	-
볼넷	11.51	O	5.19	O	4.18
사구	1.83	O	1.56	O	1.50
삼진	8.66	O	6.59	O	5.96
잔루	26.84	O	15.83	X	-
자책	224.55	X	-	-	-
승계주자실점	4.12	O	4.01	X	-
실책	2.51	O	1.77	O	1.69
타율	909.36	X	-	-	-
OPS	357.59	O	22.63	O	9.54
승계주자실점률	3.92	O	3.86	O	1.77
ERA	222.90	O	9.54	O	3.59
WHIP	35.80	O	28.68	X	-
K%	8.33	O	6.04	O	5.85
BB%	6.13	O	6.11	O	4.18
수비율	779.27	X	-	-	-

1차 다중공선성 분석을 한 결과 타수, 득점, 안타, 타점, 자책, 타율, OPS, ERA, 수비율 변인들의 분산팽창요인 계수가 100을 초과하였다. 통상적으로 100을 초과한 경우는 분산팽창요인 계수가 높다고 판단하므로 이러한 변인들은 제거해야 한다. 하지만 타수, 득점, 안타, 타율, OPS 변인들을 모두 제거할 경우 타자와 관련된 중요한 변인들이 모두 제거되므로 출루율 및 장타율을 모두 내포하고 있는 OPS 변인은 제거 변인들에서 제외하였다. 또한 자책 변인과 ERA 변인은 상관관계 분석 결과를 봤을 때 0.99로 매우 높은 상관성을 보였는데 이 두 변인을 모두 제거하기보다는 자책 변인만 제거하여 ERA 변인의 분산팽창요인 계수를 감소시켰다.

2차 다중공선성 분석을 한 결과 다중공선성에 문제가 되는 변인들은 잔루, OPS, WHIP 변인들로 나타났다. 이 변인들을 모두 제거해도 되지만 OPS 변인은 홈런 변인

을 제거하면 분산팽창요인 계수가 9.54로 감소하므로 출루율과 장타율을 내포하고 있는 OPS 변인 대신 홈런 변인을 제거하였다. 또한 승계주자실점 변인과 승계주자실점률 변인은 상관관계 분석 결과를 봤을 때 0.79로 높은 상관관계를 보였으므로 승계주자실점 변인만 제거하여 승계주자실점률 변인의 분산팽창요인 계수를 감소시켰다.

따라서 다중공선성 분석과 상관관계 분석 결과를 종합한 결과 최종적으로 기계학습 및 인공지능 모델에 사용할 기록 변인들은 볼넷, 사구, 삼진, 실책, OPS, 승계주자실점률, ERA, K%, BB%이다.



3. 데이터 표준화 및 전처리 결과

앞서 기술통계 결과를 통해 각 변인의 단위 및 범위가 상이하다는 것을 확인할 수 있었다. 기계학습 및 인공지능 모델은 기본적으로 데이터의 정규분포를 가정하기 때문에 표준화 단계를 거쳐서 각 변인의 광범위한 범위를 감소시켜야 승패 예측 결과를 도출하는 데에 용이하다. 또한 승패 분류 예측에 사용될 최종 기록 변인들을 상관관계 분석 및 다중공선성 분석을 통해 선별하였으므로 최종 데이터에는 선별된 기록 변인들이 사용된다.

팀이름, 홈/어웨이, 승패 변인들은 명명척도 변인이기 때문에 기계학습 및 인공지능 모델이 예측하기 용이하도록 팀이름 변인은 원-핫 인코딩을 통해 전처리 하였고, 홈/어웨이와 승패 변인들은 1과 0으로 전처리 하였다. 그 후 선별된 기록 변인들과 전처리 된 변인들을 합하여 표준화 처리를 하였다. 최종 데이터 예시는 <표 13>과 같다.

표 13. 최종 데이터 예시

	승 패	홈 어 웨이	볼 넷	사 구	삼 진	실 책	O P S		N C	S S G	두 산	롯데	삼성	키 움	한 화
1	1	0	0.181	-0.680	1.506	-0.825	-0.240		0	0	0	1	0	0	0
2	0	1	-0.267	-0.680	1.506	0.309	-0.444		0	0	0	0	0	1	0
3	0	0	0.629	-0.680	1.506	1.444	-0.054		0	0	0	0	0	0	1
4	1	1	-0.267	-0.680	-1.081	0.309	0.032		0	0	1	0	0	0	0
5	1	0	-0.267	0.675	0.397	-0.825	-0.639	...	0	1	0	0	0	0	0
⋮	⋮	⋮	⋮	⋮	⋮	⋮	⋮		⋮	⋮	⋮	⋮	⋮	⋮	⋮
7008	1	1	-1.164	-0.680	0.397	1.444	0.648		0	0	0	0	0	0	0
7009	0	0	-0.716	-0.680	-0.342	-0.825	-1.531		0	0	1	0	0	0	0
7010	1	1	-0.267	0.675	-1.450	-0.825	1.708		0	1	0	0	0	0	0
7011	1	0	0.181	-0.680	-0.711	-0.825	0.766		0	0	0	0	1	0	0
7012	0	1	-1.164	-0.680	-1.081	0.309	-0.992		0	0	1	0	0	0	0

4. 기계학습 및 인공지능 모델 예측 결과

승패 분류 예측을 하기 위해 랜덤포레스트 모델, XGBoost 모델, 딥러닝 모델들을 사용하였다. 랜덤포레스트 모델과 XGBoost의 하이퍼 파라미터인 $n_estimators$ 는 200으로 설정하여 200개의 의사결정나무들을 통해 승패의 분류에 대한 예측을 수행하였다.

딥러닝 모델의 구조는 3개의 평가 모델(Pilot1, Pilot2, Pilot3)을 구축한 뒤 전체 7,012개의 최종 기록 데이터에서 20%를 무작위 추출한 1,402개의 데이터를 각각의 모델에 학습시켜 승패 분류에 대한 예측을 Accuracy Score(정확도)로 비교하고 정확도가 가장 높은 평가 모델의 구조를 채택하였다. 그 후 전체 데이터에 대한 승패 분류 예측을 수행하였다.

또한 K-fold 교차검증을 진행하여 학습용 데이터와 평가용 데이터로 불균등하게 과적합되는 현상을 방지하였다. 본 연구에서는 k 를 5로 설정하여 전체 데이터를 5개로 분할한 후 $k-1$ 개를 학습용 데이터로, 나머지 1개를 평가용 데이터로 임의로 분할하여 분할된 학습용 데이터로 기계학습 및 인공지능 모델을 학습시키며 이를 k 번 반복하였다. 그 후 k 번 도출된 학습용 데이터와 평가용 데이터에 대한 평가 지표들의 평균값을 산출하여 승패 분류 예측이 얼마나 정확하게 수행되었는지 확인하였다. 본 연구에서 제시할 평가 지표는 정확도(Accuracy Score), 정밀도(Precision Score), 재현도(Recall Score), F1-Score이다. 기계학습 및 인공지능 모델의 예측 결과에 대한 내용은 다음과 같다.

1) 랜덤포레스트 모델(Random Forest)

랜덤포레스트 모델을 학습용 데이터로 학습시켰고, 이를 학습용 데이터와 평가용 데이터로 도출된 예측값으로 교차검증하여 랜덤포레스트 모델에 대한 예측정확도를 도출하였다. <표 14>, <표 15>는 학습용 데이터와 평가용 데이터를 통해 도출한 승패 분류 예측에 대한 랜덤포레스트 모델 예측정확도 표이다.

표 14. 랜덤포레스트 모델 예측정확도(학습용 데이터)

평가지표	1차	2차	3차	4차	5차	평균
Accuracy Score	1.0	1.0	1.0	1.0	1.0	1.0
Precision Score	1.0	1.0	1.0	1.0	1.0	1.0
Recall Score	1.0	1.0	1.0	1.0	1.0	1.0
F1 Score	1.0	1.0	1.0	1.0	1.0	1.0

학습용 데이터로 도출된 예측값으로 교차검증한 예측정확도의 평가지표들은 모든 회차에서 1.0이라는 결과를 나타냈고, 평균 또한 1.0을 나타냈다.

표 15. 랜덤포레스트 모델 예측정확도(평가용 데이터)

평가지표	1차	2차	3차	4차	5차	평균
Accuracy Score	0.912	0.903	0.909	0.913	0.922	0.912
Precision Score	0.916	0.909	0.922	0.911	0.904	0.912
Recall Score	0.906	0.893	0.897	0.914	0.946	0.911
F1 Score	0.911	0.901	0.909	0.913	0.925	0.912

평가용 데이터로 도출된 예측값으로 교차검증한 예측정확도의 평가지표들에서 먼저 정확도(Accuracy Score)는 1차 0.912, 2차 0.903, 3차 0.909, 4차 0.913, 5차 0.922의 결과를 보였고, 이에 대한 평균 정확도 값은 0.912로 나타났다. 정밀도(Precision Score)는 1차 0.916, 2차 0.909, 3차 0.922, 4차 0.911, 5차 0.904의 결과를 보였고, 이에 대한

평균 정밀도 값은 0.912로 나타났다. 재현도(Recall Score)는 1차 0.906, 2차 0.893, 3차 0.897, 4차 0.914, 5차 0.946의 결과를 보였고, 이에 대한 평균 재현도 값은 0.911로 나타났다. F1-Score는 1차 0.911, 2차 0.901, 3차 0.909, 4차 0.913, 5차 0.925의 결과를 보였고, 이에 대한 평균 F1-Score 값은 0.912로 나타났다.



2) XGBoost 모델

XGBoost 모델을 학습용 데이터로 학습시켰고, 이를 학습용 데이터와 평가용 데이터로 도출된 예측값으로 교차검증하여 XGBoost 모델에 대한 예측정확도를 도출하였다. <표 16>, <표 17>은 학습용 데이터와 평가용 데이터를 통해 도출한 승패 분류 예측에 대한 XGBoost 모델 예측정확도 표이다.

표 16. XGBoost 모델 예측정확도(학습용 데이터)

평가지표	1차	2차	3차	4차	5차	평균
Accuracy Score	1.0	1.0	1.0	1.0	1.0	1.0
Precision Score	1.0	1.0	1.0	1.0	1.0	1.0
Recall Score	1.0	1.0	1.0	1.0	1.0	1.0
F1 Score	1.0	1.0	1.0	1.0	1.0	1.0

학습용 데이터로 도출된 예측값으로 교차검증한 예측정확도의 평가지표들은 모든 회차에서 1.0이라는 결과를 나타냈고, 평균 또한 1.0을 나타냈다.

표 17. XGBoost 모델 예측정확도(평가용 데이터)

평가지표	1차	2차	3차	4차	5차	평균
Accuracy Score	0.925	0.919	0.929	0.933	0.926	0.926
Precision Score	0.924	0.920	0.935	0.927	0.913	0.924
Recall Score	0.925	0.915	0.926	0.940	0.942	0.930
F1 Score	0.924	0.918	0.930	0.933	0.927	0.926

평가용 데이터로 도출된 예측값으로 교차검증한 예측정확도의 평가지표들에서 먼저 정확도(Accuracy Score)는 1차 0.925, 2차 0.919, 3차 0.929, 4차 0.933, 5차 0.926의 결과를 보였고, 이에 대한 평균 정확도 값은 0.926으로 나타났다. 정밀도(Precision Score)는 1차 0.924, 2차 0.920, 3차 0.935, 4차 0.927, 5차 0.913의 결과를 보였고, 이

에 대한 평균 정밀도 값은 0.924로 나타났다. 재현도(Recall Score)는 1차 0.925, 2차 0.915, 3차 0.926, 4차 0.940, 5차 0.942의 결과를 보였고, 이에 대한 평균 재현도 값은 0.930으로 나타났다. F1-Score는 1차 0.924, 2차 0.918, 3차 0.930, 4차는 0.933, 5차는 0.927의 결과를 보였고, 이에 대한 평균 F1-Score 값은 0.926으로 나타났다.



3) 딥러닝(Deep Learning)

(1) 딥러닝 모델 구조 설정

먼저 각 평가 모델의 입력층 노드 수는 앞서 기록 변수들을 선별한 결과 20개로 설정하였다. 또한 은닉층과 출력층의 노드 수는 Pilot1은 28-1, Pilot2은 24-1, Pilot3은 17-1로 구축하였다. 또한 각 모델의 학습 반복횟수는 200으로 동일하며, 활성화 함수는 은닉층에서는 ReLU, 출력층에서는 Sigmoid를 동일하게 사용하였다. <표 18>은 Pilot1, Pilot2, Pilot3를 학습시킨 후 도출한 승패 분류 예측에 대한 예측정확도 표이다.

표 18. 평가 모델 예측정확도

모델	노드 수			평가지표
	입력층	은닉층	출력층	Accuracy Score
Pilot1	20	15+9+4=28	1	0.865
Pilot2	20	15+9=24	1	0.875
Pilot3	20	12+5=17	1	0.893

Pilot1 모델을 사용하여 승패 분류 예측을 한 결과 정확도(Accuracy Score)는 0.865, Pilot2 모델의 정확도는(Accuracy Score)는 0.875, Pilot3 모델의 정확도는(Accuracy Score)는 0.893로 나타났다. 따라서 가장 정확도 값이 높은 Pilot3의 구조(20-17-1)를 최종 딥러닝 모델의 구조로 설정하였다. <그림 13>은 최종 딥러닝 모델 구조에 대한 도식화이다.




그림 13. 최종 딥러닝 모델 구조

(2) 최종 딥러닝 모델 결과

딥러닝 모델을 학습용 데이터로 학습시켰고, 이를 학습용 데이터와 평가용 데이터로 도출된 예측값으로 교차검증하여 딥러닝 모델에 대한 예측정확도를 도출하였다. <표 19>, <표 20>은 학습용 데이터와 평가용 데이터를 통해 도출한 승패 분류 예측에 대한 딥러닝 모델 예측정확도 표이다.

표 19. 딥러닝 모델 예측정확도(학습용 데이터)

평가지표	1차	2차	3차	4차	5차	평균
Accuracy Score	0.920	0.925	0.925	0.919	0.923	0.922
Precision Score	0.916	0.926	0.922	0.926	0.921	0.922
Recall Score	0.927	0.924	0.928	0.912	0.926	0.923
F1 Score	0.921	0.925	0.925	0.919	0.923	0.923

학습용 데이터로 도출된 예측값으로 교차검증한 예측정확도의 평가지표들에서 먼저 정확도(Accuracy Score)는 1차 0.920, 2차와 3차는 0.925, 4차 0.919, 5차 0.923의 결과를 보였고, 이에 대한 평균 정확도 값은 0.922로 나타났다. 정밀도(Precision Score)는 1차 0.916, 2차 0.926, 3차 0.922, 4차 0.926, 5차 0.921의 결과를 보였고, 이에 대한 평균 정밀도 값은 0.922로 나타났다. 재현도(Recall Score)는 1차 0.927, 2차 0.924, 3차 0.928, 4차 0.912, 5차 0.926의 결과를 보였고, 이에 대한 평균 재현도 값은 0.923으로 나타났다. F1-Score는 1차 0.921, 2차 0.925, 3차 0.925, 4차 0.919, 5차 0.923의 결과를 보였고, 이에 대한 평균 F1-Score 값은 0.923으로 나타났다.

표 20. 딥러닝 모델 예측정확도(평가용 데이터)

평가지표	1차	2차	3차	4차	5차	평균
Accuracy Score	0.902	0.904	0.884	0.912	0.907	0.902
Precision Score	0.902	0.906	0.891	0.915	0.884	0.900
Recall Score	0.899	0.899	0.881	0.908	0.939	0.905
F1 Score	0.900	0.902	0.886	0.912	0.911	0.902

평가용 데이터로 도출된 예측값으로 교차검증한 예측정확도의 평가지표들에서 먼저 정확도(Accuracy Score)는 1차 0.902, 2차 0.904, 3차 0.884, 4차 0.912, 5차 0.907의 결과를 보였고, 이에 대한 평균 정확도 값은 0.902로 나타났다. 정밀도(Precision Score)는 1차 0.902, 2차 0.906, 3차 0.891, 4차 0.915, 5차 0.884의 결과를 보였고, 이에 대한 평균 정밀도 값은 0.900으로 나타났다. 재현도(Recall Score)는 1차와 2차는 0.899, 3차

0.881, 4차 0.908, 5차 0.939의 결과를 보였고, 이에 대한 평균 재현도 값은 0.905로 나타났다. F1-Score는 1차 0.900, 2차 0.902, 3차 0.886, 4차 0.912, 5차 0.911의 결과를 보였고, 이에 대한 평균 F1-Score 값은 0.902로 나타났다.



5. 변인 중요도 및 영향력 분석 결과

본 연구에서는 설명가능한 인공지능(XAI)의 SHAP를 활용하여 각 모델별로 변인의 중요도 및 영향력을 분석하였다. 그 중에서도 Global SHAP를 활용하여 K-fold 교차검증을 5회 진행하면서 사용된 평가용 데이터에서 각 변인의 긍정적 혹은 부정적 영향도를 도출하여 승패 상황에 따른 변인들의 영향력을 분석하였고, 절대적 영향도 또한 도출하여 각 변인의 중요도를 분석하였다.

1) 랜덤포레스트 모델(Random Forest)




그림 14. 랜덤포레스트 모델 절대적 영향도

<그림 14>는 랜덤포레스트 모델에 대한 각 변인의 절대적 영향도를 나타낸 그래프이다. 절대적 영향도는 ERA 변인이 가장 컸으며 OPS 변인이 그 뒤를 이었다. 이 두 변인은 각각 0.203, 0.177 영향도를 나타냈으며 다른 변인들과 비교해봤을 때 가장 높은 수치의 중요도를 나타냈다. 다음으로는 승계주자실점률 변인이 0.048, K% 변인은 0.035의 영향도를 나타냈다. 그 밖의 볼넷, 삼진, 실책, BB%, 사구 변인들은 각각 0.028, 0.024, 0.023, 0.017, 0.008의 영향도로 관찰되었다. 그리고 홈/어웨이 변인과 팀 이름 변인들은 절대적 영향도가 기록 변인들보다 낮기 때문에 랜덤포레스트 모델의 승패 분류 예측 과정에 있어서 많은 영향력을 끼치지 못했다는 것을 알 수 있었다.




그림 15. 랜덤포레스트 모델 긍정/부정 영향도

<그림 15>는 각 변인의 긍/부정 영향도를 요약한 그래프이다. 각 변인의 영향도는 ERA, OPS, 승계주자실점률, K%, 볼넷, 삼진, 실책, BB%, 사구, 홈/어웨이, 팀 이름 변인들 순으로 감소한다.

ERA, 승계주자실점률, 삼진, 실책, BB% 변인들은 그 수치가 낮을수록 승패 분류 예측값에 긍정적인 영향력을 끼쳤다고 해석할 수 있다. 즉, 투수들이 한 경기에서 볼넷을 상대팀 타자들에게 많이 허용하고 승계주자 실점을 하며 실점이 증가할수록 팀의 승리에 기여를 잘 못 한다는 것을 의미하고, 타자들은 상대팀 투수에게 삼진을 많이 당하고 수비에서는 실책을 많이 할수록 팀의 승리에 기여를 잘 못 한다는 것을 의미한다.

반대로 OPS, K%, 볼넷, 사구 변인들은 그 수치가 높을수록 승패 분류 예측값에 긍정적인 영향력을 끼쳤다고 해석할 수 있다. 이는 타자들이 한 경기에서 출루를 많이 하고 장타를 많이 치고, 볼넷과 사구를 많이 얻을수록 팀의 승리에 기여할 수 있다는 것을 의미하고, 투수들은 상대 타자들로부터 삼진을 많이 잡을수록 팀의 승리에 기여할 수 있다는 것을 의미한다.

2) XGBoost 모델




그림 16. XGBoost 모델 절대적 영향도

<그림 16>은 XGBoost 모델에 대한 각 변인의 절대적 영향도를 나타낸 그래프이다. 절대적 영향도는 ERA 변인이 4.415로 가장 컸으며 OPS 변인이 3.396로 그 다음으로 수치가 높았다. 다음으로는 홈/어웨이 변인이 0.674, 실책 변인이 0.613의 영향도를 나타냈다. 그 이외 K%, BB%, 삼진, 승계주자실점률, 볼넷, 사구 변인들이 각각 0.484, 0.357, 0.333, 0.284, 0.282, 0.158의 영향도로 확인되었다. 그리고 팀 이름 변인들은 절대적 영향도가 기록 변인들보다 그 수치가 작기 때문에 XGBoost 모델의 승패 분류 예측 과정에 있어서 많은 영향력을 끼치지 못했다는 것을 확인할 수 있었다.




그림 17. XGBoost 모델 긍정/부정 영향도

<그림 17>의 그래프를 확인했을 때 각 변인의 영향도는 ERA, OPS, 홈/어웨이, 실책, K%, BB%, 삼진, 승계주자실점률, 볼넷, 사구, 팀 이름 변인들 순으로 낮아지는 것을 확인 할 수 있었다.

ERA, 홈/어웨이, 실책, 삼진, 승계주자실점률 변인들은 그 수치가 낮을수록 승패 분류 예측값에 긍정적인 영향력을 끼쳤다고 해석할 수 있다. 즉, 팀이 어웨이 경기보다 홈 경기를 치를 때 패배하는 경향이 있고, 투수들이 한 경기에서 상대팀에게 실점을 많이 허용하고 승계주자를 실점할수록 팀의 승리에 기여를 잘 못 한다는 것을 의미한다. 또한 타자들은 상대팀 투수에게 삼진을 많이 당하고 수비에서는 실책을 많이

할수록 팀의 승리에 기여를 잘 못 한다는 것을 의미한다.

반대로 OPS, K%, 볼넷, 사구 변인들은 그 수치가 높을수록 승패 분류 예측값에 긍정적인 영향력을 끼쳤다고 해석할 수 있다. 이는 타자들이 한 경기에서 출루와 장타를 많이 기록하고, 볼넷과 사구를 많이 얻을수록 팀의 승리에 기여할 수 있다는 것을 나타내고, 투수들은 상대 타자들로부터 삼진을 많이 잡을수록 팀의 승리에 기여할 수 있다는 것을 나타낸다.



3) 딥러닝 모델




그림 18. 딥러닝 모델 절대적 영향도

<그림 18>은 딥러닝 모델에 대한 각 변인의 절대적 영향도를 나타낸 그래프이다. 절대적 영향도는 ERA 변인이 0.277로 가장 컸으며 두 번째로 OPS 변인이 0.244로 높았다. 그 다음 실책 변인이 0.040, K% 변인이 0.016의 영향도를 나타냈다. 그 밖에 삼진, 볼넷, 승계주자실점률, 사구, 홈/어웨이, BB% 변인들이 각각 0.015, 0.015, 0.014, 0.013, 0.010, 0.010의 영향도로 나타났다. 그리고 팀 이름 변인들은 절대적 영향도가 기록 변인들보다 그 수치가 작기 때문에 딥러닝 모델의 승패 분류 예측 과정에 있어서 많은 영향력을 끼치지 못했다는 것을 확인할 수 있었다.




그림 19. 딥러닝 모델 긍정/부정 영향도

<그림 19>의 그래프를 확인했을 때 각 변인의 영향도는 ERA, OPS, 실책, K%, 삼진, 볼넷, 승계주자실점률, 사구, 홈/어웨이, BB%, 팀 이름 변인들 순으로 낮아지는 것을 확인 할 수 있었다.

ERA, 실책, 승계주자실점률, 삼진 변인들은 그 수치가 낮을수록 승패 분류 예측값에 긍정적인 영향력을 끼쳤다고 해석할 수 있다. 이는 투수들이 한 경기에서 상대팀에게 실점을 많이 허용하고 승계주자를 실점할수록 팀의 승리에 기여를 잘 못 한다는 것을 의미하고, 타자들은 수비에서 실책을 많이 범하고, 상대팀 투수에게 삼진을 많이 당할수록 팀의 승리에 기여를 잘 못 한다는 것을 의미한다.

반면 OPS, K%, 볼넷, 사구 변인들은 그 수치가 높을수록 승패 분류 예측값에 긍정적인 영향력을 끼쳤다고 해석할 수 있다. 이는 타자들이 한 경기에서 출루와 장타를 많이 기록하고, 볼넷과 사구를 많이 얻을수록 팀의 승리에 기여할 수 있다는 것을 의미하고, 투수들은 상대 타자들로부터 삼진을 많이 잡을수록 팀의 승리에 기여할 수 있다는 것을 의미한다.



IV. 논의

이 연구는 한국 프로야구 정규 리그 10개 팀들의 2019년, 2020년, 2021년, 2022년, 2023년 5년 동안 무승부 경기를 제외한 경기들에서의 팀 합계 기록 데이터를 기계학습 및 인공지능 모델들을 통하여 승패 분류 예측을 하고 모델 간 비교하였다. 또한 그 예측 과정 속에서 각 변인의 영향력 및 중요도를 설명가능한 인공지능(XAI)을 통해 분석하였다. 논의하고자 하는 바는 다음과 같다.

최근 스포츠는 산업의 발전으로 인한 여러 매체의 다양화와 발달로 사람들의 인기가 증가하였다. 또한 축구와 야구뿐만 아니라 농구, 배구, 배드민턴, 테니스 등 여러 종목들이 그 인기가 증가되어 참여 스포츠로서 사람들이 많이 즐기고 있다. 이렇게 대중들의 관심 속에서 스포츠 팀 혹은 선수들은 그들의 경기력 향상을 위한 분석을 스포츠 내에서 발생하는 수많은 데이터 즉 빅데이터와 융합하여 다양한 분석 방법으로 진행하고 있다.

이기봉, 이영석과 이기청(2004)은 판별 분석을 활용하여 남자 테니스 단식 경기의 승패 요인과 득점 과정을 분석하였고, 홍종선, 정민섭과 이재형(2010)은 2010 남아공 월드컵 축구 결과를 Bradley-Terry 모형을 사용하여 예측 및 분석하였다. 또한 Mikael 등(2021)은 로지스틱 회귀 분석을 활용하여 유럽 프로축구 팀들의 리그 승격 기회 요인에 관한 연구를 진행하였다. 이렇게 스포츠에서 발생하는 데이터를 통계적인 기법을 활용하여 승패 요인 및 결과 예측 분석을 할 수 있고, 한 팀의 승격 요인에 대한 분석 또한 할 수 있다. 이러한 통계적인 기법을 활용한 분석은 접근성이 높기 때문에 여러 연구 및 활용 사례들이 많아서 참고할 수 있는 자료들이 많다. 또한 신뢰도가 높은 통계적인 방법을 사용하기 때문에 분석 결과에 대한 설명이 용이하다(정혜원, 2022).

빅데이터를 활용한 스포츠 경기 분석은 통계 분석의 기법뿐만 아니라 컴퓨터 및 기계를 활용한 분석 방법 또한 가능하다. 다양한 기계학습 및 인공지능 모델과 기법들이 스포츠에 적용되어 더욱 효과적인 분석이 가능해졌고, 방대한 데이터에 대한 접근

성 또한 기계학습 및 인공지능 모델과 더불어 증가하였다.

기계학습 및 인공지능 기법을 활용한 스포츠 경기 분석 선행 연구들을 살펴보면 최형준(2022)은 로지스틱 회귀분석, 선형 판별 분석, 인공신경망, 딥러닝, 서포트벡터머신, 나이브 베이즈 모델, XGBoost 모델 등 여러 통계 기반 기법 및 머신러닝 기법을 활용하여 축구 경기 결과 예측을 하며 이를 비교하는 연구를 발표하였고, 정혜원(2022)은 로지스틱 회귀 모델, 랜덤포레스트 모델, LightGBM 모델들을 활용하여 2018 러시아 월드컵 공식자료를 활용한 축구 경기 예측 모델을 비교하는 연구를 진행하였다.

이러한 선행 연구에서 사용된 통계적 분석 기법과 기계학습 및 인공지능 기법들을 참고하여 본 연구에서 승패 분류 예측에 사용할 모델들을 선택할 수 있었고, 랜덤포레스트 모델, XGBoost 모델, 딥러닝 모델을 선정하여 승패 분류 예측의 결과에 대한 분석을 할 수 있었다.

랜덤포레스트 모델과 XGBoost 모델 모두 앙상블 알고리즘의 대표적인 모델로서 의사결정나무를 기반으로 사용된다. 그러나 랜덤포레스트 모델은 배깅 계열로서 각 의사결정나무를 병렬 형식으로 학습시킨 후 예측값의 평균(회귀) 혹은 최빈치(분류)를 종합하여 결과값을 도출해내고, XGBoost 모델은 부스팅 계열로서 각 의사결정나무가 학습이 진행될수록 예측 결과값에 대한 오차의 최소값을 찾아나가며 가중치를 부여하고, 이전 결과값보다 더 나은 결과값을 도출해낸다(Riberio, Coelho, 2020). 또한 딥러닝 모델은 인공신경망에서 은닉층의 개수를 증가시킨 심층신경망을 활용하여 예측 결과값과 실제 값과 비교를 하며 오차값이 최소가 되는 최적의 가중치를 반복해서 찾아나가고 그 과정 속에서 모델을 업데이트시킨다.

이렇게 모델에 따라 그 구조와 특성은 다양하기 때문에 승패 분류 예측에 있어서 각기 다른 결과를 나타낼 수밖에 없다. 본 연구의 결과를 살펴보면 2019년, 2020년, 2021년, 2022년, 2023년 5년 동안의 KBO 정규리그에서 무승부 경기를 제외한 7,012 경기들의 팀 기록 데이터를 학습용 데이터와 평가용 데이터로 분할하여 학습용 데이터로 학습시킨 후 평가용 데이터를 대상으로 분석을 진행해본 결과 랜덤포레스트 모델 예측정확도의 각 평가지표는 정확도(Accuracy Score) 91.2%, 정밀도(Precision

Score) 91.2%, 재현도(Recall Score) 91.1%, F1-Score 91.2%를 기록하였고, XGBoost 모델은 정확도 92.6%, 정밀도 92.4%, 재현도 93.0%, F1-Score 92.6%를 기록하였으며, 딥러닝 모델은 정확도 90.2%, 정밀도 90.0%, 재현도 90.5%, F1-Score 90.2%를 기록하여 딥러닝 모델이 랜덤포레스트, XGBoost 모델보다 낮은 예측 정확도를 나타냈다.

위 결과를 보면 딥러닝 모델이 다른 두 모델보다 성능이 낮은 모델로 보일 수 있으나 어떠한 모델이 일반화가 잘 이루어졌는지를 확인하기 위해서는 학습용 데이터를 대상으로 도출된 예측값의 예측정확도 또한 살펴봐야 한다. 랜덤포레스트 모델과 XGBoost 모델은 모든 평가지표에서 100%를 기록하며 평가용 데이터로 도출된 예측값의 평가지표들과는 차이를 보였지만, 딥러닝 모델은 정확도 92.2%, 정밀도 92.2%, 재현도 92.3%, F1-Score 92.3%를 나타내며 많은 차이를 보이지 않았고 이를 통해 일반화가 랜덤포레스트 모델과 XGBoost 모델보다 더 잘 이루어졌다는 것을 확인할 수 있었다.

기계학습 및 인공지능 기법은 이렇게 효과적인 분석 결과를 제공해줬지만 그 결과가 도출되는 과정에 대해서는 설명을 해주지 못한다. 이러한 결과가 나오기까지 어떠한 변수들이 중요한 영향력을 끼쳤는가에 대한 질문에 답하지 못하는 블랙 박스 모델 인공지능의 단점을 가지고 있다. 이러한 단점을 보완하기 위해 변수의 영향력과 중요도를 도출해내는 설명가능한 인공지능(XAI)이 대두되고 있다. 이를 활용한 연구로는 강지연(2022)이 SHAP를 활용하여 축구 경기의 패스 공간 요인 분석 연구를 발표하였고, 조선미(2023) 또한 SHAP를 활용하여 메이저리그(MLB) 타자의 기대안타(XHA) 예측 모델 개발을 적용하는 연구를 진행하였다. 본 연구에서도 선행 연구들과 같이 SHAP를 통해 그 과정 속에서 어떠한 변수들이 중요한 영향력을 끼쳤는지 분석할 수 있었다.

설명가능한 인공지능(XAI)의 SHAP를 통해 랜덤포레스트 모델, XGBoost 모델, 딥러닝 모델의 예측 과정 속에서 사용된 변수들의 중요도를 확인해본 결과 공통적으로 ERA와 OPS 이 두 변수들이 예상과 동일하게 가장 중요한 변수로 도출되었다. 랜덤포레스트 모델의 ERA와 OPS 변수의 절대적 영향도는 각각 0.203, 0.177로 나타났으며, XGBoost 모델은 4.415, 3.396으로 나타났고, 딥러닝 모델은 0.277, 0.244를 나타

났다. XGBoost 모델이 다른 모델들보다 ERA와 OPS 변인의 절대적 영향도 수치를 가장 높게 기록하며 다른 모델들보다 이 두 변인들의 중요도를 더욱 강조하는 것을 확인할 수 있었고, 도출된 각 변인의 절대적 영향도가 모델마다 다르다는 것을 확인할 수 있었다.

또한 변인들의 긍정적 혹은 부정적 영향도를 도출하여 승패 상황에 따라서 각 변인이 어떻게 영향력을 끼치는지 확인하였다. 랜덤포레스트 모델에서는 투수들이 자책점, 승계주자실점, 볼넷 허용이 적고 삼진을 많이 잡을수록, 그리고 타자들은 출루와 장타의 수치가 높음과 동시에 볼넷과 사구를 얻는 횟수가 많고 삼진을 당하는 횟수와 실책을 범하는 횟수가 적을수록 팀 승리에 긍정적인 영향을 끼친다는 것을 확인할 수 있었다.

XGBoost 모델은 팀이 어웨이에서 경기를 하고, 투수들이 자책점, 승계주자실점 허용이 적고 삼진을 많이 잡을수록, 그리고 타자들은 출루와 장타가 많음과 동시에 볼넷 및 사구를 얻는 횟수가 많고 삼진을 당하는 횟수와 실책을 범하는 횟수가 적을수록 팀 승리에 긍정적인 영향을 끼치는 것으로 변인들의 긍/부정 영향도를 나타냈다.

딥러닝 모델은 투수들이 자책점, 승계주자실점 허용이 적고 삼진을 많이 잡을수록, 그리고 타자들은 출루와 장타가 많음과 동시에 볼넷과 사구를 얻는 횟수가 많고 삼진을 당하는 횟수와 실책을 범하는 횟수가 적을수록 팀 승리에 긍정적인 영향을 끼치는 것으로 변인들의 긍/부정 영향도를 도출하였다.

본 연구에서 변인들의 절대적 영향도와 긍/부정 영향도를 도출하면서 확인한 특이점은 세 모델 모두 팀 이름 변인들의 절대적 영향도가 기록 변인들보다 현저히 낮은 점이었다. 또한 XGBoost 모델에서 홈/어웨이 변인의 중요도가 승패 분류 예측 과정에서 다른 모델들보다 높은 수치를 기록했다는 점 있었고, 현재 KBO 역대 홈팀의 승률이 약 53%로 어웨이팀의 승률보다 높다는 것을 감안했을 때 홈/어웨이 변인이 승패에 부정적인 영향력을 끼친 점 또한 특이점이었다. 그리고 XGBoost 모델과 딥러닝 모델에서 승리에 대한 긍/부정 영향도가 모호했던 BB% 변인이 랜덤포레스트 모델에서는 수치가 낮을수록 승패 분류에 긍정적인 영향력을 끼쳤다는 것을 확인할 수 있었다.

V. 결론 및 제언

1. 결론

이 연구는 2019년, 2020년, 2021년, 2022년, 2023년 한국 프로야구(KBO) 정규리그 경기의 팀 기록을 대상으로 랜덤포레스트 모델, XGBoost 모델, 딥러닝 모델 총 세 종류의 모델을 활용하여 승패 분류 예측을 하고, 예측값에 따른 예측정확도 평가지표들을 통해 모델별로 얼마나 정확하게 예측을 하였는지 분석하였다. 또한 설명가능한 인공지능(XAI)을 활용하여 각 모델별로 승패 예측 과정 속에서 각 변인의 중요도 및 영향력을 파악하였으며 다음과 같은 결과를 확인할 수 있었다.

첫째, 승패 분류 예측에 대한 평가는 정확도(Accuracy Score), 정밀도(Precision Score), 재현도(Recall Score), F1-Score 총 네 개의 평가지표들로 진행하였다. 먼저 학습용 데이터로 도출된 예측값에 따른 예측정확도에 대한 평가지표는 랜덤포레스트 모델과 XGBoost 모델은 모두 평균 1.0을 나타냈으나, 딥러닝 모델은 정확도 평균 0.922, 정밀도 평균 0.922, 재현도 평균 0.923, F1-Score 0.923을 나타냈다. 그리고 평가용 데이터로 도출된 예측값에 따른 예측정확도에 대한 평가지표는 랜덤포레스트 모델은 정확도 평균 0.912, 정밀도 평균 0.912, 재현도 평균 0.911, F1-Score 평균 0.912를 나타냈고, XGBoost 모델은 정확도 평균 0.926, 정밀도 평균 0.924, 재현도 평균 0.930, F1-Score 평균 0.926을 나타냈으며, 딥러닝 모델은 정확도 평균 0.902, 정밀도 평균 0.900, 재현도 평균 0.905, F1-Score 평균 0.902를 나타냈다. 위 결과를 봤을 때 XGBoost 모델, 랜덤포레스트 모델, 딥러닝 모델 순으로 승패 분류 예측 성능이 좋다고 볼 수 있으나 새로운 데이터에 대한 일반화가 잘 이루어진 모델은 학습용 데이터로 도출한 예측값에 따른 예측정확도와 평가용 데이터로 도출한 예측값에 따른 예측정확도 차이가 크지 않은 딥러닝 모델로 확인할 수 있었다.

둘째, 설명가능한 인공지능(XAI)의 SHAP를 활용하여 각 모델별 승패 분류 예측 과정 속에서 나타난 각 변인의 절대적 영향도는 랜덤포레스트 모델에서 ERA, OPS, 승계주자실점률, K%, 볼넷, 삼진, 실책, BB%, 사구, 홈/어웨이, 팀 이름 변인들 순으로 높았고, 승패 분류 예측에 있어서 변인들의 긍/부정 영향도를 분석한 결과 투수들은 볼넷과 승계주자실점이 적으며 실점을 많이 허용하지 않고, 삼진을 많이 잡을수록 팀 승리에 기여도가 높았고, 타자들은 삼진을 당하는 횟수와 실책을 범하는 횟수가 적고, 출루와 장타를 많이 기록하며 볼넷과 사구를 많이 얻을수록 팀 승리에 기여도가 높았다.

XGBoost 모델에서는 변인들의 절대적 영향도가 ERA, OPS, 홈/어웨이, 실책, K%, BB%, 삼진, 승계주자실점률, 볼넷, 사구, 팀 이름 변인들 순으로 높았고, 변인들의 긍/부정 영향도를 분석한 결과 팀이 홈 경기를 치를 때 패배하는 경향을 나타냈고, 투수들은 실점과 승계주자실점이 적고, 삼진을 많이 잡을수록 팀 승리에 기여도가 높았고, 타자들은 삼진을 당하는 횟수와 실책을 범하는 횟수가 적고, 출루와 장타의 수치가 높으며 볼넷과 사구를 많이 얻을수록 팀 승리에 기여도가 높았다.

마지막으로 딥러닝 모델의 예측 과정 속에서 도출된 변인들의 절대적 영향도는 ERA, OPS, 실책, K%, 삼진, 볼넷, 승계주자실점률, 사구, 홈/어웨이, BB%, 팀 이름 변인들 순으로 높았고, 변인들의 긍/부정 영향도를 분석한 결과 투수들은 실점과 승계주자실점의 허용이 적고, 삼진을 많이 잡을수록 팀 승리에 기여도가 높았고, 타자들은 삼진을 당하는 횟수와 실책을 범하는 횟수가 적고, 출루와 장타를 많이 기록하며 볼넷과 사구를 많이 얻을수록 팀 승리에 기여도가 높았다.

결론적으로 승패 분류 예측에 대한 모델별 예측정확도는 XGBoost 모델, 랜덤포레스트 모델, 딥러닝 모델 순으로 높았으나 새로운 데이터에 대한 일반화는 딥러닝 모델, XGBoost 모델, 랜덤포레스트 모델 순으로 높았다. 또한 예측 과정 속에서 각 변인의 중요도가 모델마다 상이하게 도출되었다는 것과 승패 상황에 따른 각 변인의 영향력 또한 모델마다 상이하다는 것을 확인할 수 있었다.

2. 제언

이 연구는 2019년, 2020년, 2021년, 2022년, 2023년 한국 프로야구(KBO) 정규리그 경기의 팀 기록을 대상으로 랜덤포레스트 모델, XGBoost 모델, 딥러닝 모델 총 세 종류의 모델을 활용하여 승패 분류 예측을 하고, 예측값에 따른 예측정확도 평가지표들을 통해 모델별로 얼마나 정확하게 예측하였는지 분석하였다. 또한 설명가능한 인공지능(XAI)을 활용하여 각 모델별로 승패 예측 과정 속에서 각 변수의 중요도 및 영향력을 파악하였으며 다음과 같은 제언을 하고자 한다.

첫째, 이 연구에서는 랜덤포레스트 모델과 XGBoost 모델의 구조와 연관이 있는 하이퍼파라미터들 중 `n_estimators`만 200으로 설정하였고, 다른 하이퍼파라미터들은 모델에 설정되어 있는 기본값으로 고정해 놓았다. 기계학습 및 인공지능 모델의 하이퍼파라미터들은 그 모델의 구조와 직접적으로 연관이 있기 때문에 모델의 예측 성능 및 모델의 과적합과 일반화의 여부와도 연관이 있다. 따라서 후속 연구를 진행할 때는 랜덤포레스트 모델과 XGBoost 모델 또한 딥러닝 모델의 구조를 설정한 방식과 유사하게 하이퍼파라미터들을 수정해가며 최적의 모델을 구축해 간다면 더욱 정확하고 유의미한 결과를 도출할 수 있을 것이라 생각한다.

둘째, 이 연구에서는 변수들의 중요도 및 영향력을 설명가능한 인공지능(XAI)의 Global SHAP를 통해 교차검증을 5회 진행하면서 사용된 전체 평가용 데이터에서 도출하였다. 이는 전체적인 데이터의 경향성 및 평균적인 영향도를 의미한다. SHAP에는 Global SHAP뿐만 아니라 Local SHAP를 통하여 지역적 Shapley value 도출하여 각 경기마다의 승패 상황에서 변수들의 영향력을 분석할 수 있다. 후속 연구에서는 Local SHAP 또한 활용하여 무작위로 추출한 한 경기의 예시와 그 예시 경기 데이터에서 SHAP가 도출한 변수들의 영향력을 비교하며 어떠한 기록이 야구 경기 승패에 중요하게 영향력을 행사하였는지 분석하면 더 유용한 연구가 될 것이라고 사료된다.

참 고 문 헌

- 강지연. (2019). 기계학습 기반 축구경기 기대득점 모델 개발. 석사학위논문. 명지대학교 기록정보과학전문대학원.
- 강지연. (2022). 인공지능(eXplainable AI) 기반 축구경기의 패스 공간요인 분석. 박사학위논문. 명지대학교 대학원.
- 권순규. (2018). 한국 프로야구의 심판 합의판정 내용분석 연구. 석사학위논문. 단국대학교 대학원.
- 권순규, 이규원, & 최형준. (2019). 2016~2018 한국프로야구 세이버 메트릭스 지표 분석. **한국체육과학회지**, 28(3), 1015 - 1023.
- 김세형, 이준우, & 이미숙. (2012). Estimating the determinants of victory and defeat through analyzing records of Korean pro-basketball. **한국데이터정보과학회지**, 23(5), 993 - 1003. <https://doi.org/10.7465/jkdi.2012.23.5.993>
- 김종훈, 김경태, & 한종기. (2015). Deep Learning 기반 기계학습 알고리즘을 이용한 야구 경기 Big Data 분석 Deep Learning 기반 기계학습 알고리즘을 이용한 야구 경기Big Data 분석. **한국통신학회 학술대회논문**, 262 - 265.
- 김주학, 조선미, & 강지연. (2022). 야구 경기 승패 예측을 위한 합성곱 신경망(cnn) 최적화 연구. **한국체육측정평가학회지**, 24(4), 153 - 165.
- 김주학, & 최형준. (2014). 스포츠경기분석 연구의 국내외 주요연구동향. **한국체육측정평가학회지**, 16(1), 109 - 120.
- 김차용. (2001). 프로야구경기 분석을 통한 승, 패 예측 모형TT - A Win, Loss Predicting Model by Analyzing Professional Baseball Game. **한국사회체육학회지**, 16, 807 - 819. <http://www.dbpia.co.kr/journal/articleDetail?nodeId=NODE06242610>
- 김태훈, 임성원, 고진광, & 이재학. (2020). 인공지능 모델에 따른 한국 프로야구의 승패 예측 분석에 관한 연구. **한국빅데이터학회지**, 5(2), 77 - 84.
- 김필수, & 이상현. (2023). 빅데이터 분석을 적용한 한국프로농구 리그 정규시즌 경기결과의머신러닝 분류모형 예측성능 비교에 관한 연구.**한국체육학회지 제**, 62(2).
- 서경화. (2011). 농구경기의 공정성과 비디오판독. **한국체육철학회지**, 19(2), 37 - 52.
- 양정옥, & 이중숙. (2022). 스포츠 현장에서 인공지능 활용 방안. **한국운동역학회지**, 32(3), 69 - 79.

- 염찬욱, & 박근창. (2019). Analysis for Trend Research of Explainable Artificial Intelligence. **한국정보기술학회 종합학술발표논문집**, 88 - 89.
- 오영환. (2022). A Study on Pro-baseball Player Nomination Prediction for High School Baseball Hitter Using K-Means Clustering Method. **한국지식정보기술학회지**, 17(4), 733 - 742.
- 이기봉, 이영석, & 이기청. (2004). 국내 남자 테니스 단식 경기의 승패 요인과 득점 과정 분석. **한국체육학회지**, 43(3), 903 - 911.
- 정혜원. (2022). 2018 러시아 월드컵 공식자료를 활용한 축구경기 예측모델 비교. 석사학위논문. 단국대학교 대학원.
- 조선미. (2023). 인공지능 기반 메이저리그(MLB) 타자의 기대안타 (xHA) 예측 모델 개발 및 적용. **한국체육측정평가학회지**, 25(4), 85 - 96.
- 조선미. (2022). 인공지능 기반 한국프로야구 선발 투수 교체 예측 모형 개발. 박사학위논문. 명지대학교 기록정보과학전문대학원.
- 조선미, 김주학, 강지연, & 김상균. (2023). 머신러닝 (XGBoost) 기반 미국프로야구 (MLB) 의 투구별 안타 및 홈런 예측 모델 개발. **한국체육측정평가학회지**, 25(1), 65 - 76.
- 조억, & 김성범. (2020). 인구 기반 트레이닝 밴드 알고리즘을이용 한 강건한 하이퍼파라미터 최적화 기법. **대한산업공학회 추계학술대회 논문집**, 2136 - 2157.
- 조정환. (2012). 스포츠 빅데이터 활용과 전망. **한국체육측정평가학회지**, 14(3), 1 - 11.
- 최형준. (2020). 국내 스포츠 빅데이터 분석 연구의 현황. **한국체육측정평가학회지**, 22(2), 63 - 69.
- 최형준. (2022). 축구의 경기 결과 예측을 위한 머신러닝 기법 비교. **한국체육측정평가학회지**, 24(4), 81 - 91.
- 최형준, & 김주학. (2006). 인공신경망(Artificial Neural Network)을 이용한 2005년도 영국 웬블던 테니스 대회의 경기결과 예측에 관한 연구. **한국체육측정평가학회지**, 45(3), 459 - 467.
- 홍종선, 정민섭, & 이재형. (2010). 2010 남아공 월드컵 축구 예측모형 분석. **한국데이터정보과학회지**, 21(6), 1137 - 1146.
- 황서영. (2007). 국내프로야구 선수의 경기력 분석: KBO기록과 Sabermetrics기록의 차이점을 중심으로. 석사학위논문. 명지대학교 기록과학대학원.
- Baumer, B., & Zimbalist, A. (2014). *The sabermetric revolution: Assessing the growth of analytics in baseball*. University of Pennsylvania Press.
- Chen, T., & Guestrin, C. (2016, August). Xgboost: A scalable tree boosting system. In

Proceedings of the 22nd acm sigkdd international conference on knowledge discovery and data mining(pp. 785-794).

- Jamil, M., Liu, H., Phatak, A., & Memmert, D. (2021). An investigation identifying which key performance indicators influence the chances of promotion to the elite leagues in professional European football. *International Journal of Performance Analysis in Sport*, 21(4), 641 - 650.
<https://doi.org/10.1080/24748668.2021.1933845>
- Kato, M., & Yanai, T. (2022). Launch fly balls for better batting statistics: Applicability of "fly-ball revolution" to Japan's professional baseball league. *International Journal of Performance Analysis in Sport*, 22(3), 437 - 453.
<https://doi.org/10.1080/24748668.2022.2075302>
- Khan, S., & Kirubanand, V. B. (2019). Comparing machine learning and ensemble learning in the field of football. *International Journal of Electrical and Computer Engineering (IJECE)*, 9(5), 4321 - 4325.
<https://doi.org/10.11591/ijece.v9i5.pp4321-4325>
- Nguyen, C., Wang, Y., & Nguyen, H. N. (2013). Random forest classifier combined with feature selection for breast cancer diagnosis and prognostic. *Journal of Biomedical Science and Engineering*, 6(5), 551 - 560.
<https://doi.org/10.4236/jbise.2013.65070>
- Ribeiro, M. H. D. M., & dos Santos Coelho, L. (2020). Ensemble approach based on bagging, boosting and stacking for short-term prediction in agribusiness time series. *Applied Soft Computing Journal*, 86.
<https://doi.org/10.1016/j.asoc.2019.105837>
- Valladares, N., García-Tormo, J. V., & João, P. V. (2016). Analysis of variables affecting performance in senior female volleyball World Championship 2014. *International Journal of Performance Analysis in Sport*, 16(1), 401 - 410.
<https://doi.org/10.1080/24748668.2016.11868895>

(Abstract)

A Study on the Analysis of Win-lose Prediction Models on KBO Matches Based on AI

Yang Hae Jun

Department of Sport Science Convergence
Graduate School of Dankook University

Advisor: Prof. Choi, Hyongjun

This study aimed to compare the predictive accuracy of different models for forecasting the outcomes of regular season games in the Korean Baseball Organization(KBO) based on team records from 2019 to 2023. Additionally, it sought to analyze the importance and influence of variables within each model's prediction process using explainable artificial intelligence(XAI).

The study focused on a total of 3,506 games from the 2019 to 2023 KBO regular seasons, excluding 94 tied games. It utilized 22 independent variables, including At-Bats, Hits, Home-Runs, RBIs, Walks, Hit-by-Pitches, OPS, WHIP, ERA, and so on, along with one dependent variable, win/loss outcome.

Initially, descriptive statistics were conducted to examine the mean, standard deviation, minimum, and maximum values of each variable. Subsequently, through correlation analysis and examination of

multicollinearity, the variables to be used in predicting wins/losses were selected. Three types of models - Random Forest, XGBoost, and Deep Learning - were then used for win/loss prediction, followed by analysis of the importance and influence of variables using the SHAP method of XAI.

The results indicated that, first, the predictive accuracy of win/loss outcomes was evaluated using metrics such as accuracy, precision, recall, and F1-Score. Among the models, Random Forest exhibited an accuracy of 91.2%, precision of 91.2%, recall of 91.1%, and F1-Score of 91.1%. XGBoost showed an accuracy of 92.6%, precision of 92.4%, recall of 93.0%, and F1-Score of 92.6%, while the Deep Learning model demonstrated an accuracy of 90.2%, precision of 92.4%, recall of 90.5%, and F1-Score of 90.2%.

Secondly, using XAI's SHAP method, the absolute influence of variables used in win/loss prediction varied among the models. First, in the Random Forest model, the influence was shown in the following order: ERA, OPS, Inherited Runs Allowed Percentage(IR-A%), K%, Walks, Strikeouts, Errors, BB%, Hit-by-Pitches, Home/Away, and Team-Names. In comparison, XGBoost showed the influence in the following order: ERA, OPS, Home/Away Errors, K%, BB%, Strikeouts, IR-A%, Walks, Hit-by-Pitches and Team-Names, while Deep Learning showed the influence followed by the order: ERA, OPS, Errors, K%, Strikeouts, Walks, IR-A%, Hit-by-Pitches, Home/Away, BB% and Team-Names.

Furthermore, an analysis of the influence of variables in win/loss situations revealed nuanced effects across models. Initially, in the Random Forest model, higher strikeouts among pitchers and better on-base and slugging percentages among batters positively influenced team victories, whereas more walks, inherited-runs-allowed(IRA) and earned-runs allowed by pitchers and more errors and strikeouts committed by batters had negative influence at team victories.

In XGBoost, when teams play away games, a high number of strikeouts by pitchers, along with high on-base and slugging percentages by batters, and a high frequency of walks and hit-by-pitches, positively influence team victories. Conversely, when teams play home games, a high number of ERA and earned runs by pitchers, coupled with an increased frequency of strikeouts by batters and errors committed, negatively influence team victories.

Finally, In the case of deep learning, a high number of strikeouts by pitchers, along with high on-base and slugging percentages by batters, and a frequent occurrence of walks and hit-by-pitches, positively influence team victories. Conversely, a high number of ERA and earned runs by pitchers, coupled with an increased frequency of strikeouts by batters and errors committed, negatively influence team victories.

In conclusion, while XGBoost showed the highest predictive accuracy followed by Random Forest and Deep Learning models, generalization to new data was found to be highest for Deep Learning, followed by XGBoost and Random Forest. Moreover, through XAI, it was observed that the importance and influence of variables in the win/loss prediction process and the influence of each variable depending on the win/loss situation were different for each model.

This study contributes to baseball win/loss prediction by employing machine learning and artificial intelligence models, and by utilizing XAI to analyze the importance and influence of variables, thus addressing the limitations of black-box AI models and providing situational interpretations of win/loss outcomes.

Keywords: Baseball Performance Analysis, Machine Learning and Artificial Intelligence, win/loss Prediction, XAI, SHAP