



저작자표시-비영리-변경금지 2.0 대한민국

이용자는 아래의 조건을 따르는 경우에 한하여 자유롭게

- 이 저작물을 복제, 배포, 전송, 전시, 공연 및 방송할 수 있습니다.

다음과 같은 조건을 따라야 합니다:



저작자표시. 귀하는 원저작자를 표시하여야 합니다.



비영리. 귀하는 이 저작물을 영리 목적으로 이용할 수 없습니다.



변경금지. 귀하는 이 저작물을 개작, 변형 또는 가공할 수 없습니다.

- 귀하는, 이 저작물의 재이용이나 배포의 경우, 이 저작물에 적용된 이용허락조건을 명확하게 나타내어야 합니다.
- 저작권자로부터 별도의 허가를 받으면 이러한 조건들은 적용되지 않습니다.

저작권법에 따른 이용자의 권리는 위의 내용에 의하여 영향을 받지 않습니다.

이것은 [이용허락규약\(Legal Code\)](#)을 이해하기 쉽게 요약한 것입니다.

[Disclaimer](#)

통계학 석사학위논문

머신러닝 기법을 활용한 프로야구 승패 예측

전남대학교 대학원
수학/통계학과

김 형 우

2021년 8월

통계학 석사학위논문

머신러닝 기법을 활용한 프로야구 승패 예측

전남대학교 대학원
수학/통계학과

김 형 우

2021년 8월

머신러닝 기법을 활용한 프로야구 승패 예측

이 논문을 통계학 석사학위 논문으로 제출함

전남대학교 대학원
수학/통계학과

김 형 우

지도교수 고 봉 균

김형우의 통계학 석사 학위논문을 인준함

심사위원장 김 민 수 (인)

심사위원 정 재 식 (인)

심사위원 고 봉 균 (인)

2021년 8월

목 차

1. 서론	2
2. 기계학습 개요	4
3. 야구 승패 예측 관련 선행연구	7
4. 한국 프로야구 승패 예측	8
4.1 데이터 소개	8
4.2 변수 선택법	11
4.3 다중공선성	13
4.4 실험 설계	14
4.5 연구 결과	17
5. 결론	21
참고문헌	22

머신러닝 기법을 활용한 프로야구 승패 예측

김 형 우

전남대학교대학원 수학/통계학과

(지도교수 : 고봉균)

(국문초록)

프로야구는 현재 우리나라에서 가장 많은 관심을 받고 있는 스포츠 중 하나이다. 2012년 최초로 700만 관중을 돌파한데 이어, 2015년 KT위즈 구단이 참여 후 2016년에는 800만 관중을 돌파하는 등 나날이 관심이 커지고 있다.

야구는 한 경기에서도 많은 데이터를 쏟아낸다. 이와 더불어 많은 연구들이 이루어지고 있다. 프로야구 2020년 우승팀 NC다이노스는 데이터를 활용해 우승한 대표적인 사례이다.

본 연구에서는 기계학습 기법을 활용하여 한국 프로야구 승패 예측 분석에 관한 연구를 했다. 2018년부터 2020년까지 프로야구 10개 구단의 무승부를 제외한 4318개의 팀별 데이터를 활용하여 분석했다. 분석 방법은 투수력 데이터와 타격데이터 전체 총 43개 변수를 사용하였다. 이 중 70%는 학습용 데이터로 활용 하고 나머지 30%는 검증용 데이터로 활용하여 분석해 보았다.

변수선택법을 활용하여 입력변수를 선택하고 그 후 다중공선성이 높은 변수, 유의하지 않는 변수를 제외하고 최종적으로 변수를 선택하였다. 로지스틱 회귀분석, 서포트 벡터머신, 랜덤포레스트, 인공신경망 총 4가지 기법을 활용하여 진행해 보았다. 로지스틱 회귀분석은 96.37%의 정확도를 기록하였고 서포트 벡터머신은 96.22%, 랜덤포레스트는 96.76%, 인공신경망은 95.75%의 정확도를 기록하였다.

1. 서론

프로야구는 현재 우리나라에서 가장 많은 관심을 받고 있는 스포츠 중 하나이다. 2012년 최초로 700만 관중을 돌파한데 이어, 2015년 KT위즈 구단이 참여 후 2016년에는 800만 관중을 돌파하는 등 나날이 관심이 커지고 있다. 2020년 코로나 19가 전 세계를 강타한 상황에서도 시청률 조사기관인 TNMS의 보고에 의하면 개막전 시청자가 149만3483명에 이를 정도로 큰 인기를 누리고 있다. 이와 더불어 프로야구 팬들은 자신이 응원하는 팀의 승리 예측을 하기도 하고 경기 전 포털사이트를 통해 상대전적과 상대 데이터를 미리 살펴보고 승패에 대한 의견을 나누기도 한다.

야구는 많은 데이터를 쏟아낸다. 최근 들어 ‘데이터 야구’가 프로야구에서 트렌드로 떠오르고 있다. 각 팀마다 전력분석팀을 두고 현장과 소통하며 데이터를 야구에 접목시키고 있다. 프로야구 2020년 우승팀 NC다이노스는 데이터를 활용해 우승한 대표적인 사례이다. 외국인 선수 영입, 기존 선수 분석 뿐 아니라 선수 트레이드, 공인구 분석 등에도 활용하여 우승이라는 목표를 이룰 수 있었다.

이 뿐 아니라 프로야구 데이터를 바탕으로 많은 연구가 진행되고 있다. 머신러닝이나 인공지능망을 기반으로 한 승패예측, 세이버 매트릭스 등을 사용한 경기 결과 예측 등 프로야구 결과를 예측하기 위한 다양한 연구들이 진행되고 있다. 김동현(2016)은 Back Propagation Neural Network을 이용해 팀별 승률을 예측해 보았다.[2] 조영석 등(2007)은 2000~2005년 데이터를 바탕으로 팀 승패를 예측하기 위해 로지스틱회귀분석, 판별분석, 의사결정나무분석 기법을 사용하였다.[5] 서영진(2012)은 2006~2011년 데이터를 바탕으로 한국프로야구의 승패를 예측해 보았는데, 득점과 실점을 구분하여 예측했고, 기대 승률을 계산하여 실제 승률과 비교해 보았다.[9] 배재영(2012) 등은 2011년 데이터를 바탕으로 주성분회귀분석을 통해 프로야구 순위를 예측해 보았다. 투수부분과 타자부분, 투수와 타자부분을 혼합했을 때 각각 주성분 회귀분석 기법을 사용하였다.[10] 하지만 야구 승패 예측이 어려운 이유는 수많은 데이터 가운데 선별이 어렵고, 데이터들 간의 중복적인 요소들로 인해 모델이 좋은 성능을 보이지 못하고 있기 때문이다.

본 논문에서는 승패 예측을 위해 스탯티즈(<http://www.statiz.co.kr>)에서 2018년~2020년 팀별 데이터를 추출했다. 이 가운데 분석에 필요한 세이버 매트릭스 지표를 사용하였고, 머신러닝 기법 중 로지스틱 회귀분석, 랜덤포레스트, 서포트 벡터 머신 기법을 사용해 경기 결과를 예측해보고자 한다.

2. 기계학습 개요

기계학습이란 충분한 양의 데이터를 통해서 객관성을 갖추고 통계적으로 합리적인 결정을 내리는 기술을 의미한다.

데이터에서 의미 있는 규칙과 분류에 대한 기준을 찾아내고 데이터가 생성되는 메커니즘이나 데이터가 보여주는 개체의 특징을 알고리즘으로 파악하는 것이라고 할 수 있다. 그리고 그 학습 결과를 이용해서 새로운 데이터에 대한 예측을 제공하는 방법이 기계학습이다.

기계학습은 지도 학습과 비지도 학습 크게 2가지로 나뉘어진다. 지도학습이란 컴퓨터에 문제와 답을 제공해서 충분한 학습을 진행한 후, 해결하려는 문제를 컴퓨터에 주고 그 문제에 답하게 하는 것이 목적입니다. 회귀, 분류 등의 방법이 대표적이다. 비지도 학습은 답이 없는 문제를 컴퓨터가 풀도록 하는 목적으로 목표가 명확하지 않다. 클러스터링이나 이상치 검출 등의 방법이 대표적이다.[15]

가. 로지스틱 회귀분석

로지스틱 회귀분석(Logistic Regression)은 종속 변수의 결과가 성공 및 실패와 같이 2개의 범주가 존재하는 것을 의미한다.

로지스틱 모형 식은 독립 변수의 숫자와 상관없이 종속 변수 혹은 결과 값이 항상 $[0,1]$ 범위 안에 있도록 한다. 이는 오즈(odds)를 로짓(logit) 변환을 실행함으로 얻어지게 된다.[16]

- 오즈(odds) : 실패 확률에 비해 성공확률이 몇 배 높은가를 나타낸다.

$$odds = \frac{p(y=1|x)}{1-p(y=1|x)}$$

- 로짓 변환 : 오즈에 로그를 씌운 것을 뜻하며 입력 값의 범주가 $[0,1]$ 일 때 출력 값의 범주를 $(-\infty, +\infty)$ 로 조정해 준다.


$$\text{logit}(p) = \log \frac{p}{1-p}$$

- 로지스틱 함수 : 로지스틱 함수의 그래프는 [그림1]과 같으며 이것은 독립 변수가 주어진 경우 종속 변수가 1의 범주 안에 속할 확률을 뜻한다. 즉,

$p(y=1|x)$ 를 의미한다.

$$\text{logistic function} = \frac{e^{B_i X_i}}{1 + e^{B_i X_i}}$$

[그림1] 로지스틱 회귀함수



나. 랜덤 포레스트

랜덤 포레스트(Random Forest)는 의사결정나무들이 많이 있는 모형이다. 이를 간단히 설명해보면, 랜덤 포레스트는 다수의 의사결정나무 모형을 만들어 예측력을 높이는 것이 목적이다.


랜덤 포레스트(Random Forest)는 부스트랩 표본을 생성하고 의사결정나무 모형을 적용한 후 그 결과를 종합하는 앙상블 기법(Ensemble methods)이다. 이때 부스트랩 표본을 생성하는 부분에서 무작위성이 도입된다. 또한 의사결정나무 모형 적합 시 각 마디에서의 설명변수를 선택함에 있어서도 무작위성이 더해진다.[19] 랜덤 포레스트(Random Forest)은 높은 예측력이 장점이라고 할 수 있다. 특히 설명변수가 많을 때 예측력이 높으며 상대적으로 안정적인 모형을 제공한다.

다. SVM

서포트 벡터 머신(Support Vector Machine)은 다차원 공간 위에 있는 점들

사이에 경계를 만드는 표면이라고 할 수 있다. 여기서 점은 예시와 특징 값을 나타낸다. 서포트 벡터 머신(Support Vector Machine)의 목표는 공간을 나누어 양쪽에 균질적인 분할을 생성하는 초평면이라고 하는 경계를 생성하는 것이다.

[그림2] 서포트 벡터 머신



서포트 벡터(Support Vectors)는 각 범주에서 최대 마진 초평면에 가장 가까운 점들을 뜻한다. 서포트 벡터만을 사용하여 최대 마진 초평면을 정의할 수 있다.[20]

라. DNN

심층 신경망(Deep Neural Network)이란 입력층(input layer)과 출력층(output layer) 사이에 은닉층(hidden layer)들로 구성된 인공신경망을 의미한다. 심층 신경망은 일반적인 인공신경망과 마찬가지로 비선형 관계들을 모델링 할 수 있다. 예측력을 비교했을 때 다른 머신러닝 기법들과 비교해 상대적으로 우수한 경우들이 많고 분석 시 해당 변수들을 일정한 순서나 방식으로 넣지 않기 때문에 결과가 일정치 않다는 특징이 있다.[24]

3. 야구 승패 예측 관련 선행연구

야구에서 승패를 예측하거나 관중 수를 예측 하는 등 어떤 상황이 벌어지는 것에 예측 연구가 활발하게 이루어지고 있다.

박동주등은 Deep Neural Network 기반으로(Dropout과 Batch normalization 적용 여부에 따라 4종류로 적용) 프로야구 일일 관중 수를 예측해보았다.(논문1)

김동현은 Back Propagation Neural Network를 이용하여 팀별 공격 및 수비 세이버 매트릭스 데이터를 입력값으로 주어 10개 구단의 승률을 노드 수 7개, 12개, 15개 및 피타고리안 승률을 비교하여 예측해 보았다.[2]

조영석등은 로지스틱 회귀분석, 판별 분석, 의사결정 나무분석을 사용하여 한국프로야구 승패를 추정해 보았다. 입력 변수를 환경적 부분, 공격 부분, 수비 부분, 투수 부분으로 나누어 2000년부터 2005년까지 무승부를 제외한 데이터로 시행하였다. 로지스틱 회귀분석과 판별 분석이 82.9%로 가장 높은 추정률을 보였다.[5]

채진석등은 프로야구 포스트시즌 진출을 예측해 보기 위해 판별 분석, 이항 로지스틱 회귀분석, 인공 신경망분석 등을 이용하였다. 변인을 투수력과 관련된 변인, 타력 및 득점력과 관련된 변인, 수비와 관련된 변인, 기동력 관련된 변인으로 나누어 적중률을 비교해 보았다. 그 중 인공 신경망 분석이 91.6% 예측 적중률로 가장 높은 적중률을 보였다.[8]

노언석은 한국프로야구 승패를 예측해 보기 위해 인공신경망 모델을 적용해 보았다. 팀 변인과 타자 변인 투수 변인으로 나누고 2014년부터 2016년 까지 총 2037개 데이터를 사용하였다. 선발 투수 자책점, 투수 자책점 등을 정규화 과정을 통해 정규화 시키고 입력층에서는 쌍곡탄젠트 활성화함수를 사용하고 출력층에서는 softmax함수를 사용하였다. 실험1은 모든 변인을 사용하여 64.4%의 정확도를 보였다. 실험2는 유사변인과 비중이 작은 변인을 제외하여 실험하였고 72.3% 정확도를 보였다. 실험 3은 home팀과 away팀의 변인을 비교했을 때 높은 값을 가지면1, 낮은 값은 0, 같으면 0.5와 같이 변인을 가공하여 실험하였고 79.5%의 정확도를 보였다.[12]

4. 한국 프로야구 승패 예측

4.1 데이터 소개

본 논문에서는 2018년부터 2020년 까지 10개 구단의 무승부를 제외한 총 4318개 팀별 데이터를 수집하였다. 데이터는 경기가 끝난 후 수집된 데이터로 크게 투수력 데이터와 타격 데이터로 나뉘지며 총 43개의 변수를 사용하였다. 이 중 70%는 학습에 활용하고 나머지 30%를 검증용 데이터로 활용하였다.

[표 1] 데이터 목록

		변수명	변수 설명
목표변수		W/L	승/패
설명변수	투수DATA	H/A	홈/원정
		IP	이닝수
		TBF	상대한 타자수
		R	실점
		H	피안타
		ER	자책점
		BB	볼넷(4구)
		HBP	몸에 맞는 공(사구)
		K	삼진 아웃
		HR	피홈런
		GSC	게임스코어
		ERA	평균자책점
		WHIP	이닝당 출루 허용률
		LI	영향력 지표
		WPA	승리확률
		RE24	기대득점

	타격DATA	H/A	홈/원정
		TPA	타석수
		AB	타수
		R	득점
		H	안타
		HR	홈런
		RBI	타점
		BB	볼넷(4구)
		HBP	몸에 맞는 공(사구)
		SO	삼진 아웃
		GO	땅볼 아웃
		FO	플라이 아웃
		PIT	투구수
		GDP	더블 아웃
		LOB	잔루
		AVG	타율
		OPS	출루율+ 장타율
		LI	영향력 지표
		WPA	승리확률
		RE24	기대득점
		SO/AB	타수당 삼진당한 수
		R/AB	타수당 득점 수
		H/AB	타수당 안타 수
		HR/AB	타수당 홈런 수
		RBI/AB	타수당 타점 수
		X.BB.HBP/AB	타수당 사사구 수

4.1.1 WPA(Win Probability Added) : 승리확률 기여도

승리 확률 기여도(Win probablity Added)는 한 상황에서 다른 상황으로의 변화를 포착하고, 플레이어의 행동이 승리하는데 확률을 얼마나 높였는지를 확인하는 지표이다. 투수든 타자든 간에 한 타석에서의 결과가 해당 팀의 승리 확률에 어느 정도 영향을 미쳤는지를 수치로 표현한 후, 해당 값들을 합하여 얻어낼 수 있다. WPA는 선수의 플레이가 승리에 다가가는 데에 얼마나 도움을 주었는지를 나타낸다. 반면에 투수와 타자의 직접적인 승부에만 초점을 맞출 뿐 수비를 고려하지 않는다는 한계가 있으며, 전반적인 선수 능력을 판단하기에는 적합하지 않을 수는 있다. 본 연구에서는 WPA 지표가 큰 영향을 미칠 수 있음에 먼저 소개하고자 한다.[21]

4.1.2 RE24(Runs expectancy based on the 24 base)

RE24(Runs expectancy based on the 24 base)는 아웃 카운트와 주자 배치가 조합된 24가지 상황에 대해 해당 선수가 타석에 들어섰을 때부터 아웃되었을 때까지의 득점 기대치 변화량을 의미한다. 숫자 24가 붙은 이유는 아웃카운트(0, 1, 2) 3개의 경우와 베이스 상황(주자 없음, 1루, 2루, 3루, 1-2루, 1-3루, 2-3루, 만루)의 8개 경우의 조합을 나타내는 것이다. 쉽게 표현하면 플레이를 시작하기 전 기대 득점과 플레이가 끝난 후 기대 득점의 차이값을 뜻한다. RE24는 한 선수가 자신의 팀에 얼마나 많은 득점에 기여했는지 알려준다. RE24는 단순 통계 뒤에 매우 유용한 정보를 제공하고 있다.[22]

4.2 변수 선택법

회귀 분석에서 전체 데이터 셋 가운데 어떤 변수를 포함해야 하는가 하는 문제는 중요한 문제이다. 이에 따라 유의한 변수를 적절하게 고르는 통계적 방법에 대해 논의하게 되었고, 변수 선택법이 나오게 되었다. 변수 선택법은 가장 최적의 회귀방정식을 선택하는 데 도움을 주는 방법론이다. 변수 선택법의 종류에는 크게 전진 선택법(Forward Selection), 후진 소거법(Backward Elimination), 단계적 선택법(Stepwise Selection) 3가지로 분류된다.

이번 연구에서는 전진 선택법(Forward Selection)과 후진 소거법(Backward Elimination)을 보완한 방법인 단계적 선택법(Stepwise Selection)을 사용하여 AIC가 가장 낮은 모델을 선택하고자 한다. 그리고 선택된 모델의 변수들을 바탕으로 회귀분석을 진행해 보고자 한다.

4.2.1 전진 선택법(Forward Selection)

전진 선택법은 기존 모형에 설명력이 좋은 변수들을 하나씩 추가하는 방법이다. 절편만 있는 상수모형으로부터 중요하다고 여겨지는 설명변수부터 차례로 모형에 추가하는 방법을 뜻한다. 전진 선택법에서 변수 추가 여부는 유의수준을 통해 결정한다. 전진 선택법은 과정이 간단하여 이해하기 쉽고 변수가 많은 경우에도 사용할 수 있다는 장점이 있는 반면, 한번 선택된 변수는 계속 모형에 존재하게 되고 변수 값들의 작은 변동에도 결과가 크게 달라져 안정감이 부족하다는 단점이 있다.

4.2.2 후진 소거법(Backward Elimination)

후진 소거법은 모든 변수가 포함된 모형에서 설명력이 가장 적은 변수를 제거해 나가는 방법이다. 독립변수 후보를 전부 포함한 모형에서부터 시작해 가장 적은 영향을 미치는 변수부터 하나씩 차례로 제거하면서 더 이상 제거할 변수가 없을 때 해당 모형을 선택하는 방법이다. 후진 소거법 역시 전진 선택법과 마찬가지로

가지로 구현 과정이 비교적 간단하고 변수가 많은 상황에서도 사용할 수 있으며, 전체 변수들의 정보를 활용할 수 있다는 장점이 있다. 하지만 제외된 변수는 다시 해당 모형에 포함될 수 없으며 변수가 많은 경우에는 사용하기 어렵다는 단점이 있다.

4.2.3 단계적 선택법(Stepwise Selection)

단계별 선택법은 전진 선택법에 후진 소거법을 추가한 방법이다. 전진 선택법을 통해 변수를 추가하면서 새롭게 추가된 변수에 의한 결과가 기존 변수의 중요도보다 약화되면 해당 변수를 제거하여 단계별로 추가 혹은 제거되는 변수를 검토해 더 이상 없을 경우 중단하는 방법이다. 단계별 선택법은 구현 과정이 비교적 간단하고, 한번 들어간 변수를 계속 포함한다는 전진 선택법의 단점을 어느 정도 보완했다는 장점이 있지만, 변수가 많아지면 계산량이 늘어나거나, 일치성을 만족하지 않는다는 단점이 있다.

4.3 다중공선성

다중공선성 문제는 회귀분석 시 독립변수들 간에 상관관계가 강하게 나타날 때 발생하는 문제이다. 이것은 회귀분석의 전제 가정을 위배하는 것이기 때문에 적절한 회귀분석을 수행하기 위해 해결해야 하는 문제가 된다. 진단법으로는 결정계수 값이 높아서 회귀식의 설명력은 높은 반면 독립변수의 P-value 값이 커서 각각의 인자들이 유의하지 않을 경우 독립변수들 간에 상관관계가 높다고 의심해볼 수 있다. 기본적인 기준으로는 분산팽창요인(Variance Inflation Factor)를 구하여 해당 값이 10을 넘는 경우 다중공선성의 문제가 있다고 판단한다. 이번 연구에서도 분산팽창요인(Variance Inflation Factor) 값을 구하여 해당 값이 10을 넘는 경우 해당 변수를 제거하는 방법을 통해 다중공선성 문제를 해결하였다.[18]

$$VIF_i = \frac{1}{1 - R_i^2}$$

VIF = 다중공선성

R^2 = 결정계수

4.4 실험 설계

본 연구에서는 2018년에서 2020년까지의 날짜별 팀별 데이터를 바탕으로 예측해 보고자 한다. 팀 별 데이터는 스탯티즈에서 수집한 자료를 바탕으로 [표1]과 같이 변인을 생성하며, 자료를 생성하였다. 실험에서 사용하는 데이터는 야구 경기에서 발생하는 데이터이다.

우선 변수를 선택하기 위해 전체 변수를 대상으로 로지스틱 회귀분석을 시행하고, 단계적 선택법으로 AIC가 가장 낮은 회귀식의 변수들을 선택했다. 이렇게 해서 선택된 변수들은 아래와 같다.

[표2] 변수선택법으로 선택한 변수목록

		변수명	변수 설명
목표변수		W/L	승/패
설명변수	투수DATA	H	피안타
		K	삼진
		GSC	게임스코어
		ERA	평균자책점
		LI	영향력지표
	타격DATA	H/A	홈/원정
		TPA	타석수
		AB	타수
		R	득점
		H	안타
		HR	홈런
		RBI	타점
		BB	4구

		HBP	사구
		SO	삼진아웃
		GO	땅볼아웃
		FO	플라이아웃
		PIT	투구수
		GDP	더블아웃
		LOB	잔루
		AVG	타율
		OPS	출루율 + 장타율
		LI	영향력지표
		RE24	기대득점
		SO/AB	타수당 삼진수
		R/AB	타수당 득점수
		HR/AB	타수당 홈런수
		RBI/AB	타수당 타점수
		X.BB.HBP/AB	타수당 사사구수

다음으로는 다중공선성을 고려해 보고자 한다. 변수 선택법으로 선택된 변수들 간의 다중공선성을 확인하여 VIF 값이 10보다 큰 경우는 변수에서 제외 한다. 다중공선성을 고려하여 최종적으로 선택된 변수 목록은 아래와 같다.

[표3] 다중공선성을 고려한 변수목록

		변수명	변수 설명	VIF
목표변수		W/L	승/패	-
설명변수	투수DATA	H	피안타	2.170

		IP	이닝수	1.985
		ERA	평균자책점	4.657
		HBP	사구	1.081
		GSC	게임스코어	2.640
		LI	영향력지표	1.619
		WPA	승리확률	3.727
	타격DATA	HR	홈런	2.298
		BB	4구	1.737
		HBP	사구	1.172
		GO	땅볼 아웃	1.165
		PIT	투구수	3.487
		GDP	더블아웃	1.407
		LOB	잔루	2.496
		OPS	출루율 + 장타율	6.670
		LI	영향력지표	1.598

4.5 실험 결과

본 연구에서는 기계학습의 4가지 방법, 로지스틱 회귀분석, 서포트 벡터머신, 랜덤포레스트, 인공신경망(DNN) 기법의 정확도를 비교해보고자 한다. 학습에 70%, 검증에 30%의 데이터를 사용하였으며 분류 정확도를 바탕으로 성능을 확인해 보고자 한다.

[표4] 로지스틱 회귀분석 분류표

관측		예측값		
		결과		분류정확(%)
		패	승	
결과	패	626	25	96.16%
	승	22	623	96.59%
전체(%)		96.60%	96.14%	96.37%

[표5] 로지스틱 회귀분석 계수

변수명	estimate	std.error	z value
HR	-1.004	0.176	-5.690
BB	0.384	0.075	5.146
HBP	0.539	0.158	3.419
GO	0.1	0.047	2.126
PIT	-0.044	0.008	-4.946
GDP	-1.089	0.158	-6.899
LOB	-0.173	0.031	-5.557
OPS	26.257	1.764	14.886
LI	-1.823	0.349	-5.218

IP	1.315	0.218	6.027
H	-0.094	0.050	-1.893
ERA	-0.327	0.091	-3.605
HBP	-0.487	0.167	-2.907
GSC	-0.032	0.012	-2.641
LI	1.378	0.383	3.593
WPA	9.946	0.733	13.565

로지스틱 회귀분석은 [표4]에 나타난 바와 같이 96.37%의 분류 정확도를 기록하였고, 해당 식의 Residual deviance는 532.78(3006 degrees of freedom)으로 유의수준 0.05하에서 해당 자유도의 카이제곱 값인 3134.66보다 현저히 낮으므로 해당 로지스틱 회귀모형이 통계적으로 유의하다고 할 수 있다.

[표6] 서포트 벡터머신 분류표

관측		예측값		
		결과		분류정확(%)
		패	승	
결과	패	631	32	95.17%
	승	17	615	97.31%
전체(%)		97.08%	95.05%	96.22%

서포트 벡터머신은 [표6]에 나타난 바와 같이 1295게임 중에서 615개의 게임이 승으로 제대로 분류되었고, 631개의 게임이 패로 제대로 분류되었다. 전체 분류 정확도는 $(615 + 631) / 1295$ 로 96.22%의 분류 정확도를 기록하였다. 해당 모형의 정확도는 0.9622, 민감도(실제 발생한 승리 중 승리라고 판단된 비율)는 0.9505, 특이도(실제 발생한 패배 중 패배라고 판단된 비율)는 0.9738이며 균형정확도(민감도와 특이도의 평균값) 또한 0.9622로 분류 정확성이 매우

높은 것으로 볼 수 있다.

[표7] 랜덤포레스트 분류표

관측		예측값		
		결과		분류정확(%)
		패	승	
결과	패	633	26	96.05%
	승	16	618	97.48%
전체(%)		97.53%	95.96%	96.76%

[표8] 랜덤포레스트 결과표

Tree	MSE	%VAR(y)
100	0.02738	10.95
200	0.02662	10.65
300	0.02647	10.59
400	0.02639	10.56
500	0.02638	10.55

랜덤포레스트는 [표7]에 나타난 바와 같이 1295게임 중에서 618개의 게임이 승으로 제대로 분류되었고, 633개의 게임이 패로 제대로 분류되었다. 전체 분류 정확도는 (618+ 633)/1295로 96.76%의 분류 정확도를 기록하였다. 해당 모형의 R^2 값이 0.956로 모형의 성능이 좋음을 볼 수 있다.

[표9] 인공지능경망 분류표

관측		예측값		
		결과		분류정확(%)
		패	승	
결과	패	621	27	95.83%
	승	28	619	95.67%
전체(%)		95.69%	95.82%	95.75%

인공신경망 모형은 [표9]에 나타난 바와 같이 1295게임 중에서 619게임이 승으로 제대로 분류되었고, 621개의 게임이 패로 제대로 분류되었다. 전체 분류 정확도는 $(619 + 621) / 1295$ 로 95.75%의 분류 정확도를 기록하였다.

5. 결론

한국프로야구는 가장 인기 있는 스포츠 중 하나이다. 이런 흥행과 더불어 자신이 좋아하는 팀의 승리를 예측해 보기도 하고 실제 각 구단에서는 데이터를 바탕으로 승리를 위한 전술 및 운영을 하고 있다. 본 연구에서는 기계학습 기법을 활용하여 한국프로야구 경기에서 승패 예측 분석을 해보았다. 데이터는 경기가 끝난 후 수집된 데이터로 2018년부터 2020년까지 10개 구단의 무승부를 제외한 총 4318개 팀별 데이터를 수집하여 활용하였다.

기존 연구와는 다르게 변수 처리 단계에서는 효과적인 승패 예측을 위해 단계적 변수선택법을 활용하여 최적의 변수를 선별하였고 추가적으로 다중 공선성을 고려하기 위해 VIF가 10이 넘는 변수들은 제거하여 다중공선성 문제를 해결하고자 하였다.

예측 단계에서는 변수 처리 단계에서 선택된 변수들을 바탕으로 로지스틱 회귀분석, 서포트 벡터머신, 랜덤포레스트, DNN 총 4가지 기법을 활용하여 진행해 보았다. 로지스틱 회귀분석은 96.37%의 정확도를 기록하였고 서포트 벡터머신은 96.22%, 랜덤포레스트는 96.76%, DNN은 95.75%의 정확도를 기록하였다. 각 모델이 통계적으로 유의한지도 결과를 통해 나타내었다. 4가지 기법 모두 매우 높은 정확도를 보여주었지만 그 중에서도 랜덤포레스트, 로지스틱 회귀분석, 서포트 벡터머신, DNN 기법 순으로 높은 정확도를 보여주었다. 보통 DNN이 높은 적중률을 보여주는 거에 반해 랜덤포레스트 기법이나 서포트 벡터머신 기법이 더 높은 적중률을 보이는 것으로 보아 하이퍼 파라미터에 최적값을 설정하는 것이 중요함을 알 수 있다.

본 연구에서 우리가 쉽게 구할 수 있는 데이터를 바탕으로 기계학습 기법을 활용하여 승패를 예측해 보았지만 향후에는 투수와 타자의 세부지표 및 엔트리 현황과 승패 예측, 인플레이 타구 비율을 통한 승패 예측, 2군 운영 데이터와 승패 예측 등 다양한 변수들을 활용하거나 인공지능망 모델 등 다양한 모델을 바탕으로 예측할 수 있도록 추가적인 연구가 필요하다.

참고문헌

- [1] 박동주, 김병우, 정영선, 안창욱 (2018). Deep Neural Network 기반 프로 야구 일일 관중 수 예측 : 광주-기아 챔피언스 필드를 중심으로(2018)
- [2] 김동현 (2016). BPNN을 이용한 프로 야구 리그 팀별 승률 예측 모델
- [3] 홍석미, 정경숙, 정태충 (2003). 혼합형 기계 학습 모델을 이용한 프로야구 승패 예측 시스템
- [4] 이장택, 김용태 (2007). 한국프로야구에서 승률 예측을 위한 효율적인 통계적 모형
- [5] 조영석, 조용주, 신상근 (2007). 한국프로야구에서 승패 추정에 관한 연구
- [6] 이장택, 조현식 (2009). 한국프로야구에서 데이터마이닝을 이용한 팀대 팀 승패모형
- [7] 조영석, 허태영, 박찬근, 한준태 (2010). A Statistical Analysis of Professional Baseball Team Data: The Case of the Lotte Giants
- [8] 채진석, 조은형, 엄한주 (2010). 프로야구 포스트시즌 진출 예측을 위한 통계적 모형 비교
- [9] 서영진 (2017). 기계학습 기법을 이용한 한국프로야구 승패 예측 모델
- [10] 배재영 (2012). 주성분회귀분석을 이용한 한국 프로야구 순위
- [11] 채진석, 송종국 (2014). 한국프로야구 Post시즌 전력분석 및 예측모형

- [12] 노언석 (2016). 인공지능망을 이용한 KBO 프로야구 승부예측 연구
- [13] 김순귀, 이영훈 (2016). 한국 프로야구의 승률 추정
- [14] 이장택 (2016). 한국프로야구에서 승률 추정방법들의 비교
- [15] 요코우치 다이ске 외. 다양한 그래프, 간단한 수학, R로 배우는 머신러닝 (p12-13)
- [16] 위키백과, “로지스틱 회귀분석”,
https://ko.wikipedia.org/wiki/%EB%A1%9C%EC%A7%80%EC%8A%A4%ED%8B%B1_%ED%9A%8C%EA%B7%80
- [17] 홍종선, 함주형, 김호일 (2005). 수정 결정계수를 사용한 로지스틱 회귀모형에서의 변수선택법
- [18] 위키백과, “다중공선성”,
<https://ko.wikipedia.org/wiki/%EB%8B%A4%EC%A4%91%EA%B3%B5%EC%84%A0%EC%84%B1>
- [19] 유진은 (2015). 랜덤 포레스트: 의사결정나무의 대안으로서의 데이터 마이닝 기법
- [20] 브레트 란츠. R을 활용한 머신러닝 2/e (p330-332)
- [21] 야구 공작소 위키
<http://ko.yagongso.wikidok.net/wp-d/5a58cb76db66db827362bf2a/View>
- [22] RE24, <https://www.fmkorea.com/best/1310968173>

[23] 허민석, 나의 첫 머신러닝/딥러닝 (p193-195)

[24] 위키백과, “딥러닝”,

https://ko.wikipedia.org/wiki/%EB%94%A5_%EB%9F%AC%EB%8B%9D

Prediction of Professional Baseball win or loss using machine learning techniques

HYUNG WOO KIM

Department of Mathematics/Statistics
Graduate School Chonnam National University
(Supervised by Professor Bong Gyun Ko)

(Abstract)

Professional baseball is currently one of the most popular sports in our country. After surpassing 7 million spectators for the first time in 2012, KT Wiz's club participated in 2015 and surpassed 8 million spectators in 2016.

Baseball spills a lot of data in one game. Along with this, a number of studies are being done. NC Dinos, the winner of the 2020 professional baseball league, is a case in point of winning by utilizing data.

In this study, we used machine learning techniques to analyze the prediction of winning or losing of Korean professional baseball. From 2018 to 2020, the team analyzed data from 4318 teams, excluding draws by 10 professional baseball teams. The analysis method used a total of 43 variables, including pitching power data and hitting data. Of these, 70% were used as learning data, and the remaining 30% were used as verification data was analyzed.

The variable selection method was utilized to select the input variable,

and then finally the variable was selected except for variables with high multicollinearity and non-significant variables. We proceed using a total of four techniques: logistic regression, support vector machines, random forests, and deep neural networks. Logistic regression analysis recorded 96.37% accuracy, support vector machines recorded 96.22%, random forest 96.76% and deep neural networks 95.75%.